- # Лекция 2

Введение

- ### Основные шаги прогнозирования

Задача прогнозирования обычно состоит из пяти основных шагов.

Шаг 1: Определение проблемы.

Часто это самая сложная часть прогнозирования.

Тщательное определение проблемы требует понимания того,

- как будут использоваться прогнозы,
- кому они нужны, и
- как функция прогнозирования вписывается в организацию, требующую прогнозов.

Прогнозисту необходимо потратить время на общение со всеми, кто будет участвовать в сборе данных, поддержании баз данных и использовании прогнозов для будущего планирования.

Шаг 2: Сбор информации.

Всегда требуется как минимум два вида информации:

- статистические данные и
- накопленный опыт людей, которые собирают данные и используют прогнозы.

Часто бывает трудно получить достаточно исторических данных, чтобы соответствовать хорошей статистической модели. В этом случае можно использовать оценочные методы прогнозирования.

Иногда старые данные будут менее полезными из-за структурных изменений в прогнозируемой системе; тогда мы можем использовать только самые свежие данные.

Однако помните, что хорошие статистические модели учитывают эволюционные изменения в системе; не выбрасывайте хорошие данные без надобности.

Шаг 3: Предварительный (поисковый) анализ.

Всегда начинайте с графического представления (визуализации) данных.

- Есть ли закономерности?
- Есть ли значимая тенденция?
- Важна ли сезонность?
- Есть ли доказательства наличия бизнес-циклов?
- Есть ли какие-либо выбросы в данных, которые должны быть объяснены специалистами?
- Насколько сильны взаимосвязи между переменными, доступными для анализа?

Для помощи в этом анализе были разработаны различные инструменты (лабораторный практикум и семинары).

Шаг 4: Выбор и примерка моделей.

Наилучшая модель для использования зависит от

- наличия исторических данных,
- силы связей между переменной прогноза и любыми независимыми переменными,
- а также от способа использования прогнозов.

Обычно сравнивают две или три потенциальных модели.

Каждая модель сама по себе является искусственной конструкцией, которая основана на наборе допущений (явных и неявных) и обычно включает один или несколько параметров, которые должны быть оценены с использованием известных исторических данных.

Шаг 5: Использование и оценка модели прогнозирования.

После того, как модель выбрана и ее параметры оценены, модель используется для

- составления прогнозов и
- интерпретации результатов прогнозирования.

Эффективность модели можно правильно оценить только после того, как станут доступны данные за прогнозный период.

Был разработан ряд методов, помогающих оценить точность прогнозов.

Существуют также организационные вопросы использования прогнозов и действий на их основе.

При использовании модели прогнозирования на практике возникает множество практических вопросов, например,

- как обрабатывать недостающие значения
- что делать с выбросами
- или как работать с короткими временными рядами.

• Основные модели математического прогнозирования

На прошлом занятии мы обсуждали перечень основных моделей и методов прогнозирования, включающий:

- регрессионные модели:
  - линейная регрессия,
  - нелинейная регрессия (в том числе logit-, tobit- и т.д.);
- **модели временных рядов:**
  - авторегрессионные модели (ARIMAX, GARCH, ARDLM);
  - модель экспоненциального сглаживания;
  - модели на базе цепей Маркова;
- модель по выборке максимального подобия;
- нейросетевые модели;
- модели на базе классификационно-регрессионных деревьев;
- имитационное модели;
- и т.д.

• Примеры данных

Пример 1.1. (Квартальная прибыль Johnson & Johnson)

На рис. 1.1 показана квартальная прибыль на акцию для американской компании Johnson & Johnson.

- 84 квартала (21 год) с 1 квартала 1960 г. по последний квартал 1980 г.

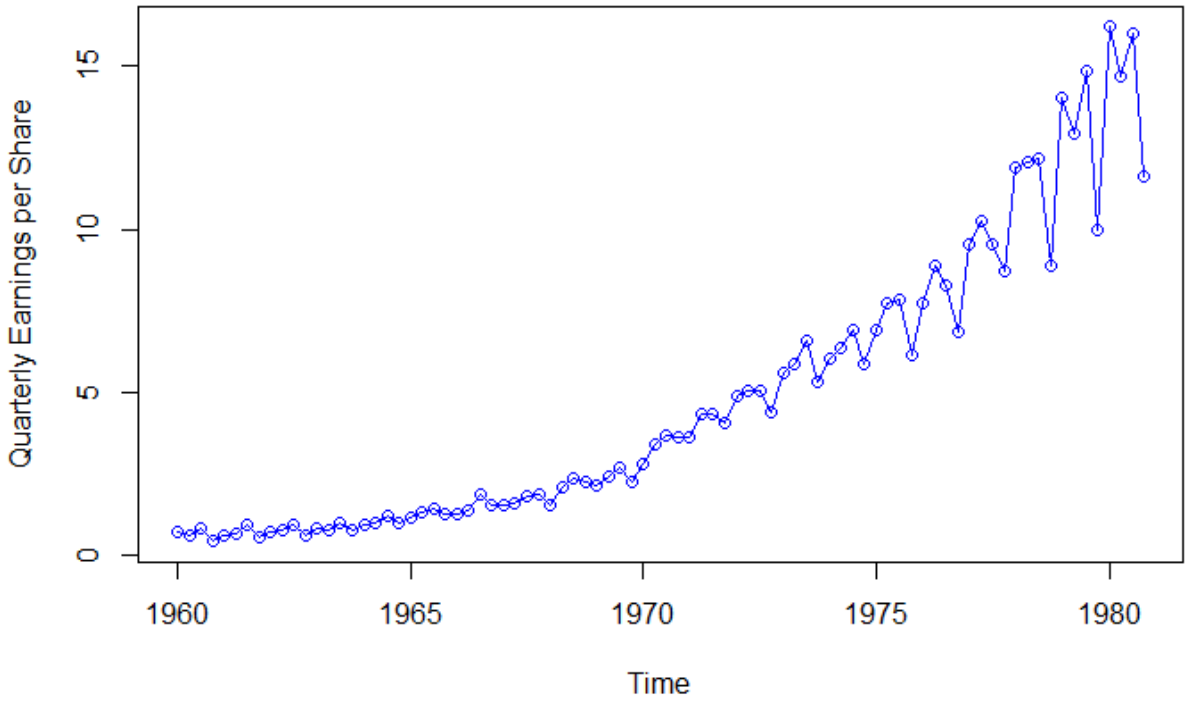


Рис. 1.1. Johnson & Johnson: квартальная прибыль на акцию

```
library(astsa)
par(mar=c(4,4,2,.5))
plot(jj, type="o", ylab="Quarterly Earnings per Share",col="blue")
```

Пример 1.2. (Глобальное потепление)

На рисунке 1.2. показано изменение глобальной средней температуры океан-земля за период 1880-2009 гг. с базой 1951-1980гг.

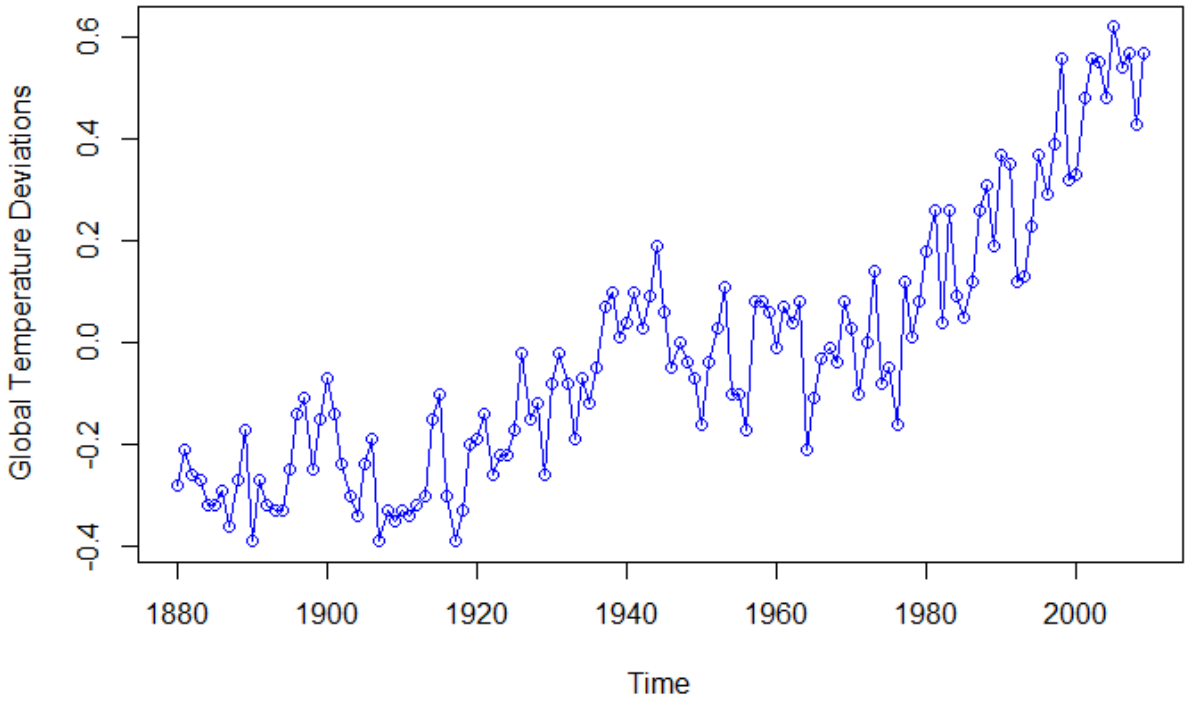


Рис. 1.2. Отклонения среднегодовой глобальной температуры (1880-2009) в градусах Цельсия

```
library(astsa)
par(mar=c(4,4,2,.5))
plot(gtemp, type="o", ylab="Global Temperature Deviations",col="blue")
```

Пример 1.3. (Google)

На рисунке 1.3. показаны цены на акции компании Google с 2007 по н.в..

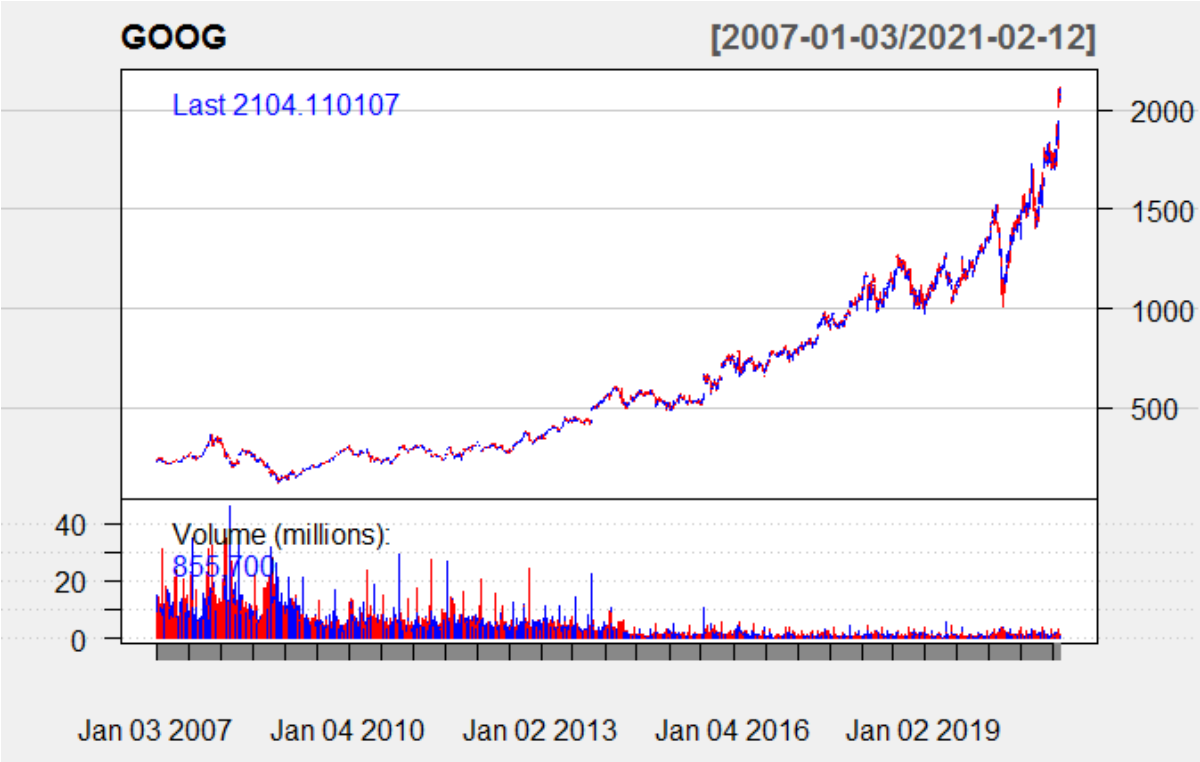


Рис. 1.3. Цены на акции компании Google

```
library(quantmod)
getSymbols("GOOG")
barChart(GOOG,
         bar.type = "ohlc",
         theme = chartTheme("white"),
         up.col = "blue",
         dn.col = "red")
```

• Понятие временного ряда

• Определение

Временной ряд – это набор наблюдений $\{x_t\}$, каждое из которых наблюдается в определенный момент времени t.

> Определение 1.1. **Модель временных рядов** определяет совместное распределение последовательности случайных величин $\{X_t\}$:
>
> $$P\{X_1 \le x_1, \dots, X_t \le x_t\}$$
>
> для всех $\{x_t\}$ и t,
>
> где $\{X_t\}$ – стохастический процесс, а $\{x_t\}$ – его реализация.

В действительности мы можем наблюдать временной ряд только конечное число раз, и в этом случае основная последовательность случайных величин – является просто -мерной случайной величиной (или случайныv

вектором). Однако часто бывает удобно, чтобы количество наблюдений было бесконечным. В этом случае (или, более обобщающе: или) называется *случайным процессом*.

- **Примеры**

Пример 1.4. (iid-шум, iid-процесс)

Простейшая модель временного ряда, которая не содержит ни трендовой, ни временной компоненты, а компоненты ряда независимы и одинаково распределены – это, так называемый, iid-шум.

Определение 1.2. Процесс называется **iid-шумом** с нулевым средним и дисперсией и записывается как

$$X_t \sim IID(0, \sigma^2)$$

если случайные величины – независимые и одинаково распределенные с

Математически, для любых и

$$P\{X_1 \le x_1, \dots, X_t \le x_t\} = \prod_t F(x_t)$$

где – функция распределения каждого .

Поскольку

$$X_t | X_1, \dots, X_{t-1} = X_t$$

то сам по себе iid-шум не интересен для прогнозирования, но важен с практической и теоретической точек зрения.

Пример 1.5. (бинарный (дискретный) процесс)

На рисунке 1.4 представлен пример iid-шума, называемый *бинарным процессом*, для которого последовательность независимых одинаково распределенных случайных величин (iid-последовательность) имеет распределение:

$$P\{X_t = -1\} = P\{X_t = 1\} = \frac{1}{2}$$

Пример 1.6. (Гауссовский шум (непрерывный процесс))

Если iid-последовательность нормальных случайных величин с нулевым средним и дисперсией называется *Гауссовским шумом* (рис. 1.4):

Пример 1.7. (случайное блуждание)

Случайное блуждание (начинающееся в нулевой точке) – это сумма (или «интегрирование») случайных величин:

$$S_t = X_1 + \cdots + X_t$$

где (рис. 1.4.)

Заметим, что «дифференцируя», мы можем восстановить процесс

$$\nabla S_t = S_t - S_{t-1} = X_t$$

Далее, имеем:

$$E\{S_t\} = 0,$$
$$D\{S_t\} = t\sigma^2$$

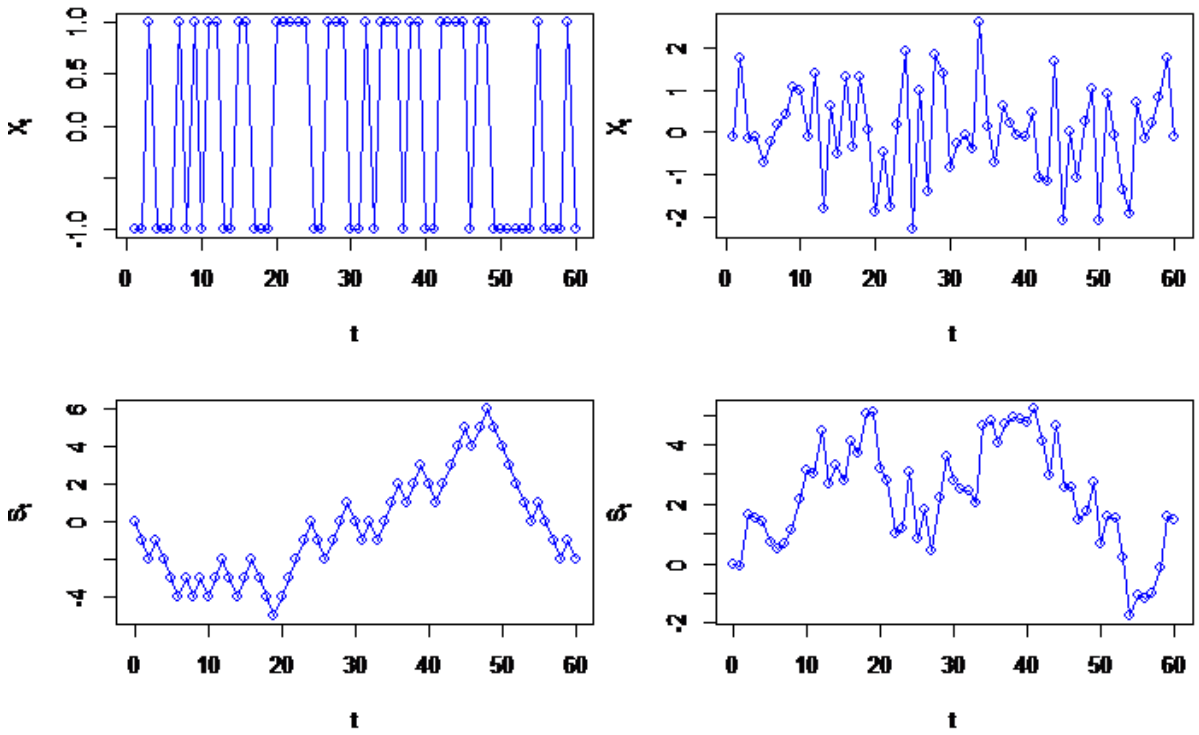


Рис. 1.4. Вверху: реализация бинарного процесса (слева) и Гауссовского шума (справа). Внизу: соответствующие процессы случайного блуждания

```
set.seed(100); par(mfrow=c(2,2)); par(mar=c(4,4,2,.5))
t=seq(1,60,by=1); Xt1=rbinom(length(t),1,.5)*2-1
plot(t,Xt1,type="o",col="blue",xlab="t",ylab=expression(X[t]))
t=seq(1,60,by=1); Xt2=rnorm(length(t),0,1)
plot(t,Xt2,type="o",col="blue",xlab="t",ylab=expression(X[t]))
plot(c(0,t),c(0,cumsum(Xt1)),type="o",col="blue",
      xlab="t",ylab=expression(S[t]))
plot(c(0,t),c(0,cumsum(Xt2)),type="o",col="blue",
      xlab="t",ylab=expression(S[t]))
```

Пример 1.8. (белый шум)

Случайный процесс называется *белым шумом* и записывается как

$$X_t \sim WN(0, \sigma^2)$$

если некоррелированны, то есть

$$E\{X_t\} = 0, D\{X_t\} = \sigma^2,$$
$$Cov\{X_{t_1}, X_{t_2}\} = 0, t_1 \neq t_2$$

для любых , и

Отметим, что каждый IID-шум является белым шумом, но не наоборот!

Пример 1.9. (пример белого шума, но не iid – процесса)

Определим процесс

$$X_t = \begin{cases} Z_t, \text{если } t \text{ нечетное} \\ \sqrt{3}Z_{t-1}^2 - \dfrac{2}{\sqrt{3}}, \text{если } t \text{ четное} \end{cases}$$

где Z_t- iid последовательность с распределением вероятностей

$$Z_t, t = 1, 3, 5, \ldots$$

$$P\{Z_t = -1\} = P\{Z_t = 0\} = P\{Z_t = 1\} = \frac{1}{3}$$

Легко показать, что

$$E\{X_t\} = 0, D\{X_t\} = \frac{2}{3}, Cov = 0$$

Однако, последовательность не является iid-шумом, так как элемент полностью определяется элементом :

Пример реализации процесса на рисунке 1.5.

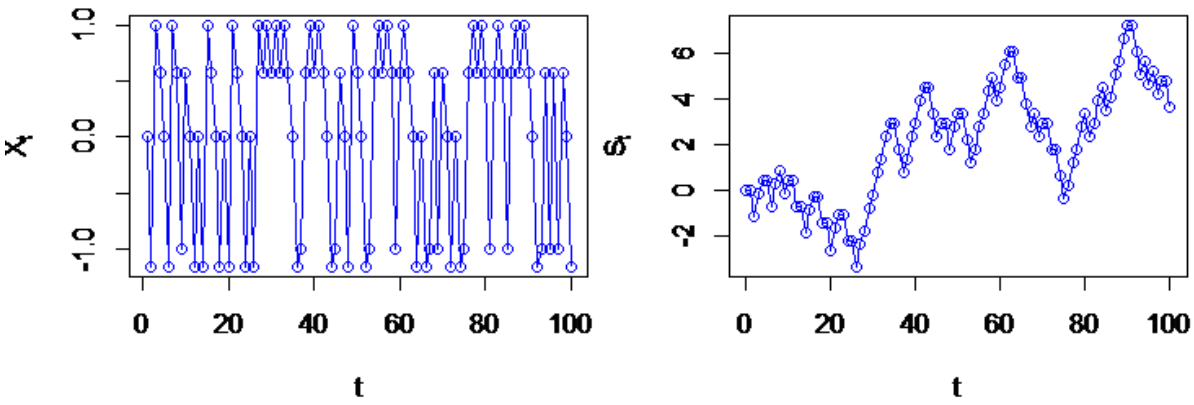


Рис. 1.5. Реализация примера 1.9

```
set.seed(100); par(mfrow=c(1,2)); par(mar=c(4,4,2,.5))
t=seq(1,100,by=1); res=c(-1,0,1)
Zt=sample(res,length(t)/2,replace=TRUE); Xt=c()
for(i in 1:length(Zt)){
  Xt=c(Xt,c(Zt[i], sqrt(3)*Zt[i]^2-2/sqrt(3)))}
plot(t,Xt,type="o",col="blue",xlab="t",ylab=expression(X[t]))
plot(c(0,t),c(0,cumsum(Xt)),type="o",col="blue",xlab="t",
      ylab=expression(S[t]))
```

Пример 1.10. (плавные скользящие средние)

Это существенно непараметрический метод оценки тренда. Требуются средние значения наблюдений около ; т.е. сглаживает ряд. Например, пусть

$$X_t = \frac{1}{3}(W_{t-1} + W_t + W_{t+1})$$

представляет собой трехточечное скользящее среднее ряда белого шума . На рисунке 1.6 представлена реализация: скользящее среднее показывает более гладкую версию первого ряда:

- более медленные колебания более очевидны,
- а некоторые из более быстрых, но незначительных колебаний исключены.

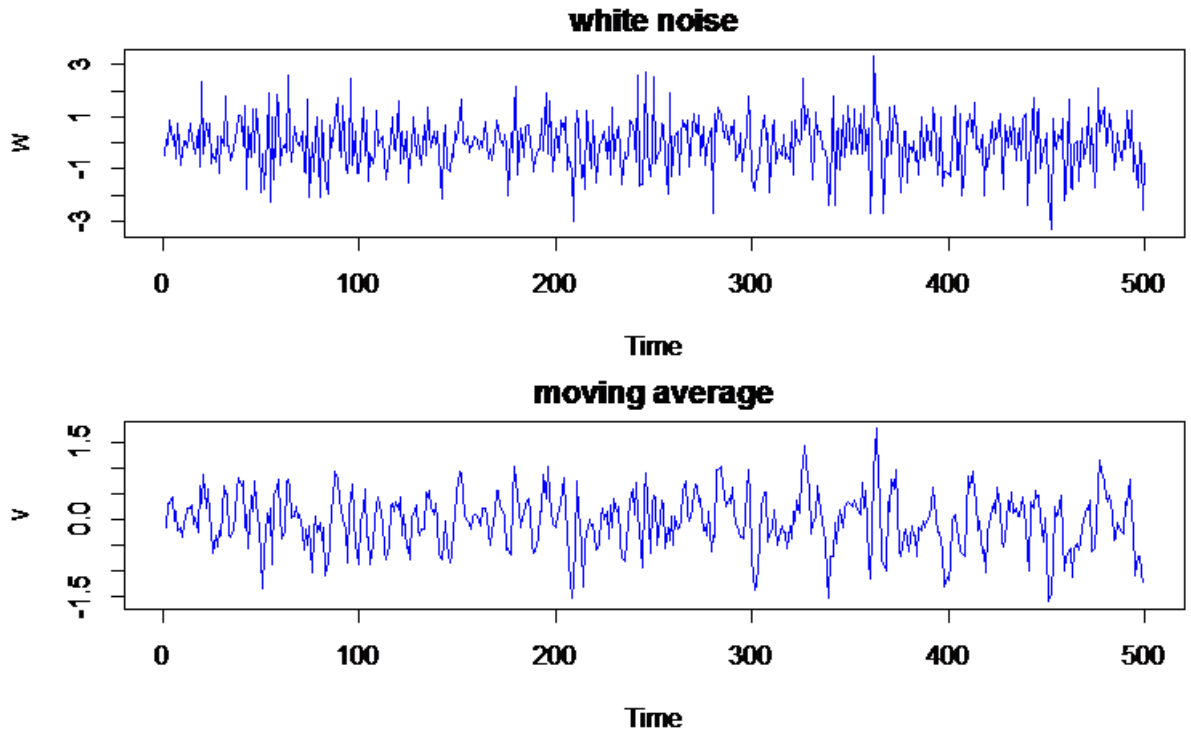


Рис. 1.6. Гауссовский белый шум (вверху) и трех-точечное сглаженное Гауссовского белого шума (внизу)

```
set.seed(100); w = rnorm(500,0,1) # 500 N(0,1) variates
v = filter(w, sides=2, rep(1/3,3)) # moving average
par(mfrow=c(2,1)); par(mar=c(4,4,2,.5))
plot.ts(w, main="white noise",col="blue")
plot.ts(v, main="moving average",col="blue")
```

Пример 1.11. (AR(1) – авторегрессия первого порядка)

Пусть

$$X_t = 0.6\, X_{t-1} + W_t$$

где

Процесс представляет собой регрессию или прогноз текущего значения временного ряда как функцию двух последнего значения ряда.

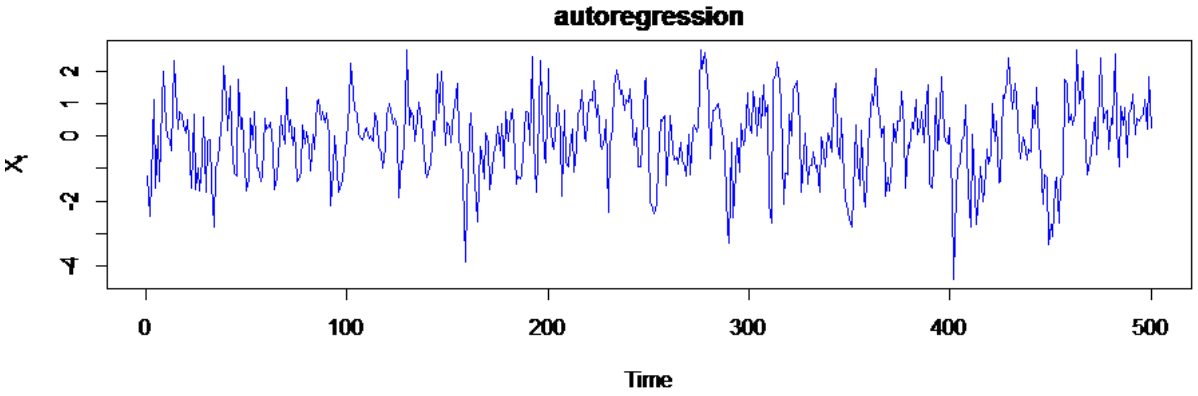


Рис. 1.7. Реализация авторегрессии

```
set.seed(100); par(mar=c(4,4,2,.5))
w = rnorm(550,0,1) # 50 extra to avoid startup problems
x = filter(w, filter=c(.6), method="recursive")[-(1:50)]
plot.ts(x, main="autoregression",col="blue",ylab=expression(X[t]))
```

Пример 1.12. (случайное блуждание со смещением)

Пусть

$$X_t = \delta + X_{t-1} + W_t$$

где

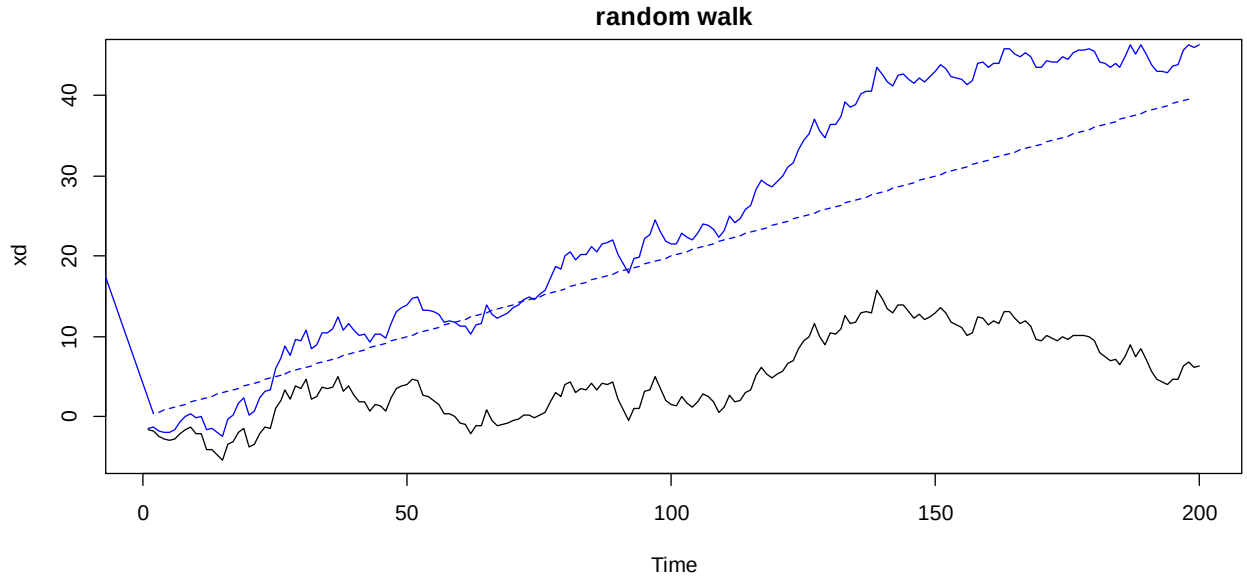


Рис. 1.8. Случайное блуждание

```
set.seed(150); w = rnorm(200,0,1); x = cumsum(w);
wd = w +.2; xd = cumsum(wd); par(mar=c(4,4,2,.5))
plot.ts(xd, ylim=c(-5,45), main="random walk",col="blue")
lines(x); lines(.2*(1:200), lty="dashed",col="blue")
```

Пример 1.13. (Сигналы)

Рассмотрим модель

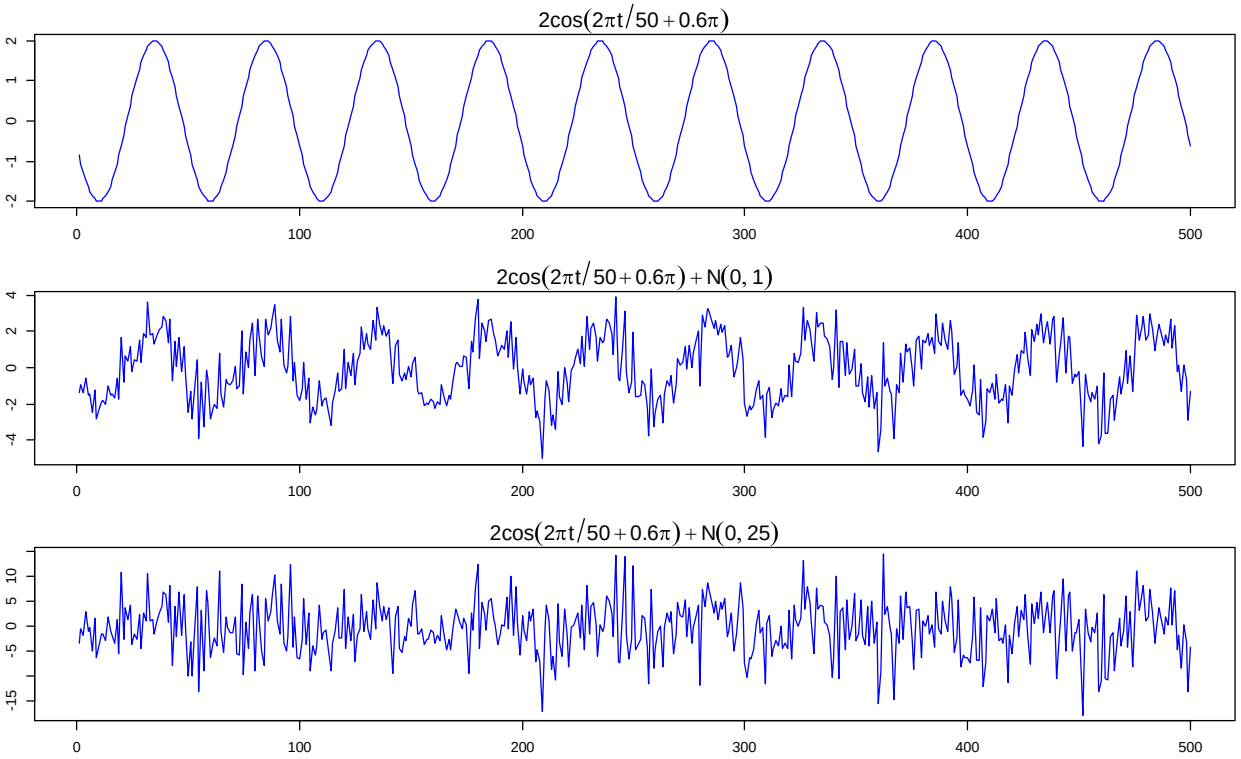


Рис. 1.9. Периодические сигналы в рядах

```
set.seed(100); cs = 2*cos(2*pi*1:500/50 + .6*pi); w = rnorm(500,0,1)
par(mfrow=c(3,1), mar=c(3,2,2,1), cex.main=1.5)
plot.ts(cs, main=expression(2*cos(2*pi*t/50+.6*pi)),col="blue")
plot.ts(cs+w, main=expression(2*cos(2*pi*t/50+.6*pi) +
N(0,1)),col="blue")
plot.ts(cs+5*w, main=expression(2*cos(2*pi*t/50+.6*pi) +
N(0,25)),col="blue")
```