Часть I

Теоретический материал

Глава 1. Примеры моделей временных рядов
Глава 2. Стационарные процессы
Глава 3. Процесс авторегрессии и скользящего среднего ARMA
Глава 4. Анализ нестационарных временных рядов

Введение

Глава 1

Примеры моделей временных рядов

1.1. Тренд и сезонность

1.1. Тренд и сезонность

1.1.1. Декомпозиция временного ряда
1.1.2. Временные ряды без сезонной компоненты
1.1.3. Тренд и сезонность

1.1.1. Декомпозиция временного ряда

Рассмотрим «классическую декомпозицию» модели временного ряда [11]:

$$X_t = m_t + s_t + Y_t, \tag{1.1}$$

где

- m_t — это медленно изменяющаяся функция, так называемая «*тредновая компонента*»;
- s_t — это функция с известным периодом d («*сезонная компонента*»;);
- Y_t — стационарный временной ряд.

Наша главная цель — это выделить и оценить детерминированные компоненты m_t и s_t в надежде, что остаточная компонента Y_t окажется стационарным временным рядом.

1.1.2. Временные ряды без сезонной компоненты

Предположим, что во временном ряде (1.1) отсутствует сезонная компонента, то есть:

$$X_t = m_t + Y_t,\ t = 1, 2, \ldots, n.$$

Не нарушая общности полагаем, что $\mathbf{E}\{Y_t\} = 0$.

Существует три основных метода выделения трендовой компоненты m_t:

1) Предополагается явный вид функции m_t с точностью до параметров (параметрическая неопределенность) и производится оценка этих параметров.

2) Производится сглаживание с помощью скользящих средних.

3) Производится дифференцирование, чтобы получить стационарный временной ряд.

Параметрическое выделение тренда

Предположим, что трендовая составляющая есть функция известного вида, зависящая от времени, и определена с точностью до параметров, например:

$$m_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2,$$

тогда оценки параметров $\{\hat{\alpha}_0, \hat{\alpha}_1, \hat{\alpha}_2\}$ можно вычислить с помощью метода наименьших квадратов, минимизирующего сумму квадратов остатков:

$$\sum_{t=1}^{n} \left(X_t - \alpha_0 - \alpha_1 t - \alpha_2 t^2\right)^2 \to \min_{\{\alpha_0, \alpha_1, \alpha_2\}}.$$

Сглаживание с помощью скользящих средних

Пусть q — некоторое целое неотрицательное число и построим *сглаженый ряд*

$$sma_t = sma_t(q, X) = \frac{1}{2q+1} \sum_{j-q}^{q} X_{t+j},\ q+1 \leqslant t \leqslant n-q. \tag{1.2}$$

Тогда,

$$sma_t = \frac{1}{2q+1} \sum_{j-q}^{q} m_{t+j} + \frac{1}{2q+1} \sum_{j-q}^{q} Y_{t+j} \approx m_t,$$

то есть

$$\hat{m}_t = sma_t$$

Если $t \leqslant q$ или $t > n-q$, то необходима модификация формулы (1.2), например:

$$\hat{m}_t = \sum_{j=0}^{n-t} \alpha(1-\alpha)^j X_{t+j},\ \text{для } t = 1, \ldots, q,$$

$$\hat{m}_t = \sum_{j=0}^{n-t} \alpha(1-\alpha)^j X_{t-j},\ \text{для } t = n-q+1, \ldots, n.$$

Два этих требования к q может быть трудно выполнить одновременно. Поэтому рассмотрим *линейный фильтр*:

$$\hat{m}_t = \sum \alpha_j X_{t+j}, \tag{1.3}$$

где $\sum \alpha_j = 1$ и $\alpha_j = \alpha_{-j}$.

Такой фильтр позволяет восстанавливать линейный тренд без искажений, поскольку:

$$\sum \alpha_j (a + b(t+j)) = (a+bt) \sum \alpha_j + b \sum \alpha_j j = (a+bt) \times 1 + 0 = a + bt.$$

Линейный фильтр (1.3) связан со сглаженным процессом (1.1.2) через параметры $\{\alpha_j\}$:

$$\alpha_j = \begin{cases} \frac{1}{2q+1} & \text{для } |j| \leqslant q \\ 0 & \text{для } |j| > q \end{cases}$$

Замечание 1.1. Веса $\{\alpha_j\}$ в фильтре (1.3) можно подбирать таким образом, чтобы без искажений восстанавливать и другие, более сложные виды тренда. Например, применяя 15-точечное скользящее среднее Спенсера [**?**] с параметрами:

$$[\alpha_0, \alpha_{\pm1}, \ldots, \alpha_{\pm7}] = \frac{1}{320}[74, 64, 46, 21, 3, -5, -6, -3] \text{ и } \alpha_j = 0 \text{ для } |j| > 7,$$

к временному ряду с кубическим тредом

$$m_t = at^3 + bt^2 + ct + d,$$

получим

$$\hat{m}_t \approx \sum \alpha_j m_{t+j} = m_t.$$

Дифференцирование для стационарности

Определим оператор взятия *первой разности* ∇ как

$$\nabla X_t = X_t - X_{t-1} = (1 - B)X_t,$$

где B — это оператор *обратного сдвига* (лага) $(BX)_t = X_{t-1}$.

Обобщая:

$$\nabla^k X_t = \nabla(\nabla^{k-1} X)_t.$$

Пример 1.1. Например,

$$\nabla^2 X_t = \nabla X_t - \nabla X_{t-1} =$$
$$(X_t - X_{t-1}) - (X_{t-1} - X_{t-2}) = X_t - 2X_{t-1} + X_{t-2}.$$

Пример 1.2. В качестве иллюстрации «исчисления операторов» приведем другое «доказательство»:

$$\nabla^2 X_t = (1 - B)^2 X_t = (1 - 2B + B^2)X_t = X_t - 2X_{t-1} + X_{t-2}.$$

Предположим, трендовая составляющая является линейной:

$$m_t = a + bt,$$

тогда получаем

$$\nabla X_t = \nabla m_t + \nabla Y_t = a + bt - a - b(t-1) + \nabla Y_t = b\nabla Y_t$$

и

$$\begin{gathered}\mathbf{Cov}\{\nabla Y_t, \nabla Y_s\} = \\ = \mathbf{Cov}\{Y_t, Y_s\} - \mathbf{Cov}\{Y_{t-1}, Y_s\} - \mathbf{Cov}\{Y_t, Y_{s-1}\} + \mathbf{Cov}\{Y_{t-1}, Y_{s-1}\} = \\ = \gamma_y(t-s) - \gamma_y(t-s-1) - \gamma_y(t-s+1) + \gamma_y(t-s) = \\ = 2\gamma_y(t-s) - \gamma_y(t-s-1) + \gamma_y(t-s+1).\end{gathered}$$

Таким образом, процесс ∇X_t является стционарным.

Лемма 1.1. *[?]. Если трендовая компонента является полиномом степени k:*

$$m_t = \sum_{j=0}^{k} c_j t^j,$$

то процесс

$$\nabla^k X_t = k! c_k + \nabla^k Y_t.$$

является стационарным.

1.1.3. Тренд и сезонность

Вернемся к рассмотрению модели (1.1):

$$X_t = m_t + s_t + Y_t,$$

где

- $\mathbf{E}\{Y_t\} = 0$,
- $s_{t+d} = s_t$ и $\sum_{k=1}^{d} s_k = 0$.

Для простоты полагаем d целым числом.

Наиболее распространенные значения для периода d:

- 24 для периода: день, единица времени: часы;
- 7 для периода: неделя, единица времени: дни;
- 12 для периода: год, единица времени: месяцы;
- 4 для периода: год, единица времени: кварталы.

Иногда данные удобно индексировать по периоду и единице времени:

$$x_{j,k} = x_{k+d(j-1)},\ k = 1, \ldots, d,\ j = 1, \ldots, \lfloor \frac{n}{d} \rfloor,$$

то есть $x_{j,k}$ — это наблюдение в $k-$ый момент времени $j-$го периода.

Основные методы:

1) малых трендов;
2) оценка скользящим средним;
3) дифференцирование по лагу d.

Малые тренды

Естественно рассматривать тренд как постоянный в течение каждого периода, то есть мы рассматриваем модель:

$$X_{j,k} = m_j + s_k + Y_{j,k}.$$

Тогда, естественно оценивать трендовую и сезонные компоненты какЖ

$$\hat{m}_j = \frac{1}{d}\sum_{k=1}^{d} X_{j,k} \text{ и } \hat{s}_k = \frac{d}{n}\sum_{j=1}^{\lfloor \frac{n}{d} \rfloor}(X_{j,k} - \hat{m}_j).$$

Оценка скользящим средним

Сначала мы вычислим скользящее среднее, чтобы устранить сезонные колебания и ослабить шум. Для четного d используем $q = \frac{d}{2}$ и оценку:

$$\hat{m}_t = \frac{0.5X_{t-q} + X_{t-q+1} + \ldots + X_{t+q-1} + 0.5X_{t+q}}{d},$$

а для нечетного d используем $q = \frac{d-1}{2}$ и оценку:

$$\hat{m}_t = \frac{X_{t-q} + X_{t-q+1} + \ldots + X_{t+q-1} + X_{t+q}}{d},$$

для $q + 1 \leqslant t \leqslant n - q$.

Для того, чтобы оценить s_k сначала вычислим «естественые» оценки:

$$w_k = \frac{1}{\text{количество слагаемых}} \sum_{\frac{q-k}{d} < j \leqslant \frac{n-q-k}{d}} (X_{k+jd} - \hat{m}_{k+jd}).$$

Замечание 1.2. Обратите внимание, что это «только» конечные эффекты вынуждают нас к этой формально сложной оценке. На самом деле мы берем среднее значение тех $X_{k+jd} : s$, где $m_{k+jd} : s$ может быть оценено.

Для того, чтобы достигнуть условия, накладываемого на сезонную компоненту $\sum_{k=1}^{d} \hat{s}_k = 1$ получаем оценку:

$$\hat{s}_k = w_k - \frac{1}{d}\sum_{i=1}^{d} w_i, \ k = 1, \dots d.$$

Дифференцирование по лагу d

Определим оператор *дифференцирования по лагу d* ∇_d как:

$$\nabla_d X_t = X_t - X_{t-d} = (1 - B^d)X_t.$$

Тогда

$$\nabla_d X_t = \nabla_d m_t + \nabla_d Y_t,$$

не имеет сезонной компоненты, и мы можем применять методы раздела 1.1.2.

Глава 2

Стационарные процессы

2.1. Меры зависимости
2.2. Модели временных рядов
2.3. Линейные процессы

2.1. Меры зависимости

2.1.1. Автоковариационная функция
2.1.2. Стационарность случайных процессов
2.1.3. Спектральная плотность

2.1.1. Автоковариационная функция

Пусть функция математического ожидания случайного процесса $\{X_t\}$ $\mu_x(t) = \mathbf{E}\{X_t\}$ существует. Тогда *автоковариационной функцией* процесса $\{X_t\}$ называется

$$\gamma_X(s,t) = \mathbf{Cov}\{X_s, X_t\} = \mathbf{E}\left\{(X_s - \mu_X(s))(X_t - \mu_X(t))\right\}. \tag{1.1}$$

Перечислим основные свойства для ковариации и корреляции. Для любых случайных величин X, Y, Z справедливо:

1) $\mathbf{Cov}\{X,Y\} = \mathbf{E}\{XY\} - \mathbf{E}\{X\}\mathbf{E}\{Y\}$
2) $\mathbf{Corr}\{X,Y\} = \rho_{XY} = \frac{\mathrm{Cov}\{X,Y\}}{\sqrt{\mathrm{Var}\{X\}\mathrm{Var}\{Y\}}}$
3) $-1 \leqslant \rho_{XY} \leqslant 1$ для любых X и Y
4) $\mathbf{Cov}\{X,X\} = \mathbf{Var}\{X\}$
5) $\mathbf{Cov}\{X,Y\} = \mathbf{Cov}\{Y,X\}$
6) $\mathbf{Cov}\{aX,Y\} = a\mathbf{Cov}\{X,Y\}$
7) $\mathbf{Cov}\{b+X,Y\} = \mathbf{Cov}\{X,Y\}$
8) Если X и Y независимы, то $\mathbf{Cov}\{X,Y\} = 0$
9) Если $\mathbf{Cov}\{X,Y\} = 0$, то это не означает независимость X и Y
10) $\mathbf{Cov}\{X+Y,Z\} = \mathbf{Cov}\{X,Z\} + \mathbf{Cov}\{Y,Z\}$
11) $\mathbf{Cov}\{\sum_{i=1}^n a_i X_i, \sum_{j=1}^m b_j Y_j\} = \sum_{i=1}^n \sum_{j=1}^m a_i b_j \mathbf{Cov}\{X_i, Y_j\}$

2.1.2. Стационарность случайных процессов

Говорят, что случайный процесс $\{X_t\}$ *стационарен в широком смысле* (*weakly stationary*), если:

- $\mathbf{Var}\{X_t\} < \infty$ для всех t,
- $\mu_X(t) = \mu$ для всех t,
- $\gamma_X(r,s) = \gamma_X(r+t, s+t)$ для всех r, s, t,
- поскольку из предыдущего пункта следует, что $\gamma_X(r,s)$ зависит только от разницы $r-s$, то удобно определить
$$\gamma_X(h) \stackrel{\text{def}}{=} \gamma_X(h,0).$$
Величина «h» называется *отставанием* (*лагом*).

Говорят, что случайный процесс $\{X_t\}$ *стационарен в узком смысле (или строго стационарен)* (*stricly (or strongly) stationary*), если:
$$(X_{t_1}, \ldots, X_{t_k}) \text{ и } (X_{t_1+h}, \ldots, X_{t_k+h})$$
имеют одно и тоже совместное распределение вероятностей для всех $k = 1, 2, \ldots$, $h = 0, \pm 1, \pm 2, \ldots$ и для всех точек отсчета $t_1, \ldots, t_k$.

Процесс, стационарный в узком смысле и с конечной дисперсией, является стационарным в широком смысле. Но, стационарный в широком смысле процесс не обязательно должен быть быть стационарным в узком смысле.

Пример 1.1. Например, определим случайный процесс $\{X_t\}$ как последовательность независимых величин:
$$X_t \sim \begin{cases} Exp(1), & \text{если } t \text{ четное,} \\ \mathcal{N}(1,1), & \text{если } t \text{ нечетное.} \end{cases}$$

Таким образом, $\{X_t\} \sim WN(1,1)$ но не является $IID(1,1)$ процессом.

Теорема 1.1. *Основные свойства стационарного в узком смысле случайного процесса* $\{X_t\}$*:*

1) *Величины* X_t *имеют одинаковое распределение.*

2) *Для всех целых* t *и* k *справедливо:*

$$(X_t, X_{t+j}) =^d (X_1, X_{1+j}).$$

3) *Если* $\mathbf{E}\{X_t^2\} < \infty$ *для всех* t*, то процесс стационарен в широком смысле.*

4) *Из стационарности в широком смысле не следует стационарность в узком смысле.*

5) *Последовательность i.i.d. (независимых одинаково распределенных случайных величин) стационарна в узком смысле.*

Доказательство. [11] ■

Пример 1.2. q**-зависимый временной ряд стационарный в узком смысле.** Одним из простейших способов построить временной ряд $\{X_t\}$, который является стационарным в узком смысле, — это «профильтровать» i.i.d. последовательность. Пусть $\{Z_t\} \sim IID(0, \sigma^2)$, определим

$$X_t = g(Z_t, Z_{t-1}, \ldots, Z_{t-q}),$$

для некоторой действительной функции $g() \in \mathbb{R}$. Тогда ряд $\{X_t\}$ является стационарным в узком смысле и одновременно q-зависим: то есть X_s и X_t независимы, только тогда, если $|t - s| > q$.

Процесс $\{X_t\}$ называется *Гауссовским процессом*, если n-мерный вектор $\mathbf{X} = (X_{t_1}, \ldots, X_{t_n})$ для любого набора точек $t_1, \ldots, t_k$ и любого положительного n имеет многомерное гауссовское распределение.

Теорема 1.2. *Гауссовский процесс, стационарный в широком смысле, является стационарным в узком смысле.*

Доказательство. Достаточно показать, что каждый стационарный в широком смысле Гауссовский процесс является стационарным в узком смысле. Предположим, что это не так, значит, должны существовать $(t_1, t_2)^T$ и $(t_1 + h, t_2 + h)^T$ такие, что случайные векторы $(X_{t_1}, X_{t_2})^T$ и $(X_{t_1+h}, X_{t_2+h})^T$ имеют различное распределение, что противоречит определению Гауссовского процесса и стационарности в широком смысле. ■

В дальнейшем, говоря «стационарность» будем иметь ввиду ***стационарность в широком смысле***.

Пусть $\{X_t\}$ стационарный временной ряд, то есть $\mu_X = \mu_X(t)$. *Автоковариационной функцией (ACVF)* ряда $\{X_t\}$ на лаге h является

$$\gamma_X(h) = \mathbf{Cov}\{X_{t+h}, X_t\}. \tag{1.2}$$

Автокорреляционной функцией (ACF) ряда $\{X_t\}$ на лаге h является

$$\rho_X(h) = \frac{\gamma_X(h)}{\gamma_X(0)} = \mathbf{Corr}\{X_{t+h}, X_t\}. \tag{1.3}$$

Действительная функция $f : \mathbb{Z} \to \mathbb{R}$ называется *неотрицательно определенной* (или *положительной полуопределенной*), если

$$\sum_{i,j=1}^{n} a_i f(t_i - t_j) a_j \geqslant 0$$

для любого n и для всех векторов $a \in \mathbb{R}^n$ и $t \in \mathbb{Z}^n$.

Теорема 1.3. *Действительная функция $f : \mathbb{Z} \to \mathbb{R}$ является неотрицательно определенной тогда и только тогда, если она является автоковариационной функцией стационарного временного ряда.*

Доказательство.

«**Если**». Пусть $\gamma(\cdot)$ автоковариационноая функция стационарного временного ряда $\{X_t\}$. Так же она будет являться автоковариационной функцией процесса $Z_t = X_t - \mu_x$. Тогда

$$\Gamma_n = \begin{pmatrix} \gamma(t_1 - t_1) & \dots & \gamma(t_1 - t_n) \\ \vdots & \ddots & \vdots \\ \gamma(t_n - t_1) & \dots & \gamma(t_n - t_n) \end{pmatrix}$$

ковариационная матрица $\mathbf{Z}_t = \begin{pmatrix} Z_{t_1} \\ \vdots \\ Z_{t_n} \end{pmatrix}$ и имеем:

$$0 \leqslant \mathbf{Var}\{a^T \mathbf{Z}_t\} = a^T \mathbf{E}\{\mathbf{Z}_t \mathbf{Z}_t^T\} a = a^T \Gamma_n a = \sum_{i,j=1}^{n} a_i \gamma(t_i - t_j) a_j.$$

«**Только**». Пусть функция $f : \mathbb{Z} \to \mathbb{R}$ является неотрицательно определена, и необходимо найти стационарный процесс $\{X_t\}$, такой, что $\gamma_X(h) = f(h)$ для любого целого h. Это просто сделать, выбирая $\{X_t\}$ Гауссовским процессом, таким, чтобы $\mathbf{Cov}\{X_i, X_j\} = f(i - j)$ для любых i и j.

■

Теорема 1.4. *Основные свойства автоковариационной функции* $\gamma_X(\cdot)$*:*

1) $\gamma_X(0) \geqslant 0$ *для любого* h*;*
2) $|\gamma_X(h)| \leqslant \gamma_X(0)$ *для любого* h*;*
3) $\gamma_X(h) = \gamma_X(-h)$ *для любого* h*;*
4) γ_X *является неотрицательно определенной.*

Доказательство.
Первое свойство очевидно, так как для любых t выполняется

$$\gamma_X(0) = \mathbf{Cov}\{X_t, X_t\} = \mathbf{Var}\{X_t, X_t\} \geqslant 0.$$

Второе свойство основывается на неравенстве Коши-Буняковского [**?**]:

$$|\gamma_X(h)| = |\mathbf{Cov}\{X_{t+h}, X_t, \}| \leqslant \sqrt{\mathbf{Var}\{X_t, X_t\}}\sqrt{\mathbf{Var}\{X_{t+h}, X_{t+h}\}} = \gamma_X(0).$$

Третье свойство выполняется поскольку:

$$\gamma_X(h) = \mathbf{Cov}\{X_{t+h}, X_t, \} = \mathbf{Cov}\{X_t, X_{t+h}\} = \gamma_X(-h).$$

Четвертое свойство следует из теоремы 1.3. ■

Замечание 1.1. Автокорреляционная функция $\rho(\cdot)$ имеет все свойства автоковариационной функции и удовлетворяет дополнительному условию: $\rho(0) = 1$

2.1.3. Спектральная плотность

Предположим, что

$$\sum_{h=-\infty}^{\infty} |\gamma(h)| < \infty.$$

Тогда, функция f вычисляемая как

$$f(\lambda) = \frac{1}{2\pi} \sum_{h=-\infty}^{\infty} e^{-ih\lambda}\gamma(h), \ -\pi \leqslant \lambda \leqslant \pi, \tag{1.4}$$

строго определена. Мы имеем:

$$\int_{-\pi}^{\pi} e^{ih\lambda} f(\lambda) d\lambda = \int_{-\pi}^{\pi} \frac{1}{2\pi} \sum_{k=-\infty}^{\infty} e^{i(h-k)\lambda}\gamma(k) d\lambda = \frac{1}{2\pi} \sum_{k=-\infty}^{\infty} \gamma(k) \int_{-\pi}^{\pi} e^{i(h-k)\lambda} d\lambda = \gamma(h).$$

Функция f, вычисляемая по (1.4) называется *спектральной плотностью* временного ряда $\{X_t, t \in \mathbb{Z}\}$.

Спектральная плотность имеет много замечательных свойств. Здесь же обратим вниманием, что

$$f(0) = \frac{1}{2\pi} \sum_{h=-\infty}^{\infty} \gamma(h).$$

2.2. Модели временных рядов

2.2.1. Стационарность типичных временных рядов
2.2.2. Идентификация нестационарных временных рядов
2.2.3. Выборочная ACVF
2.2.4. «Гид»
2.2.5. Выводы

2.2.1. Стационарность типичных временных рядов

«Тригонометрический» временной ряд

Рассмотрим временной ряд

$$X_t = A\cos(\theta t) + B\sin(\theta t), \tag{2.1}$$

где A и B некоторые некоррелируемые случайные величины с нулевым математическим ожиданием и дисперсией, равной 1, с $\theta \in [-\pi, \pi]$. Тогда:

$$\mu_X(t) = 0;$$

$$\begin{aligned}\gamma_X(t+h, h) &= \mathbf{E}\{X_{t+h}X_t\} \\ &= \mathbf{E}\{(A\cos(\theta t + \theta h) + B\sin(\theta t + \theta h))(A\cos(\theta t) + B\sin(\theta t))\} \\ &= \cos(\theta t + \theta h)\cos(\theta t) + \sin(\theta t + \theta h)\sin(\theta t) \\ &= \cos(\theta t + \theta h - \theta t) = \cos(\theta h).\end{aligned}$$

Автоковариационная функция не зависит от t, таким образом $\{X_t\}$ стационарный процесс. Более того:

$$\rho_X(h) = \cos(\theta h).$$

Белый шум

Для процесса белого шума $\{W_t\} \sim WN(0, \sigma^2)$ имеем:

$$\mu_w = 0, \quad \gamma_w(h) = \begin{cases} \sigma^2 & \text{если } h = 0; \\ 0 & \text{иначе,} \end{cases}, \quad \rho_w(h) = \begin{cases} \sigma^2 & \text{если } h = 0; \\ 0 & \text{иначе,} \end{cases}.$$

```
rho=function(h,theta){I(h==0)*1}
h=seq(-5,5,1); s=1:length(h); y=rho(h,.6)
plot(h,y,xlab="h",ylab=expression(rho[X](h)))
segments(h[s],y[s],h[s],0,col="blue")
```

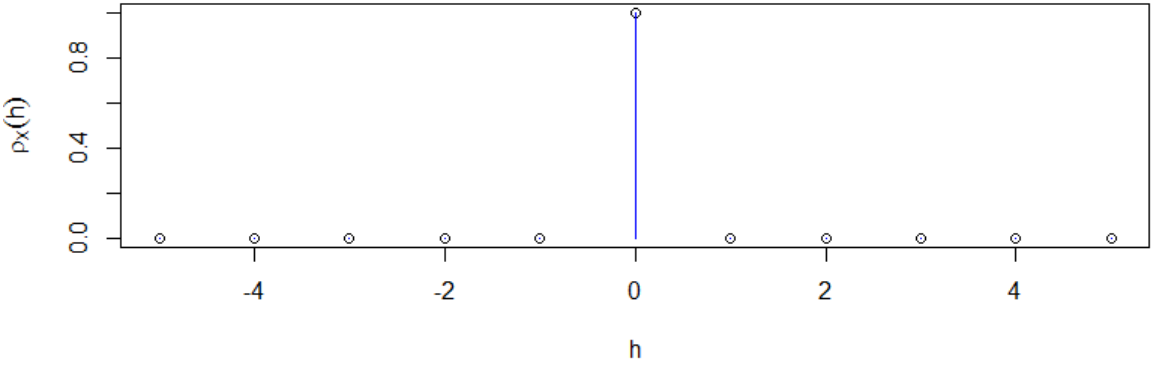


Рисунок 2.1. ACF для процесса белого шума

3-х точечное скользящее среднее

В примере **??** рассматривался процесс:

$$X_t = \frac{1}{3}(W_{t-1} + W_t + W_{t+1}),$$

где $\{W_t\} \sim WN(0, \sigma^2)$. Тогда:

$$\mu_X(t) = \mathbf{E}\{X_t\} = \frac{1}{3}\left(\mathbf{E}\{W_{t-1}\} + \mathbf{E}\{W_t\} + \mathbf{E}\{W_{t+1}\}\right) = 0,$$

$$\gamma_X(t+h, t) = \frac{3}{9}\sigma^2 I(h=0) + \frac{2}{9}\sigma^2 I(|h|=1) + \frac{1}{9}\sigma^2 I(|h|=2),$$

не зависит от t для любых h. Таким образом процесс $\{X_t\}$ стационарный. Далее

$$\rho_X(h) = I(h=0) + \frac{2}{3}I(|h|=1) + \frac{1}{3}I(|h|=2).$$

```
rho=function(h,theta){I(h==0)+2/3*I(abs(h)==1)+1/3*I(abs(h)==2)};
h=seq(-5,5,1); s=1:length(h); y=rho(h,.6);
plot(h,y,xlab="h",ylab=expression(rho[X](h)));
segments(h[s],y[s],h[s],0,col="blue")
```

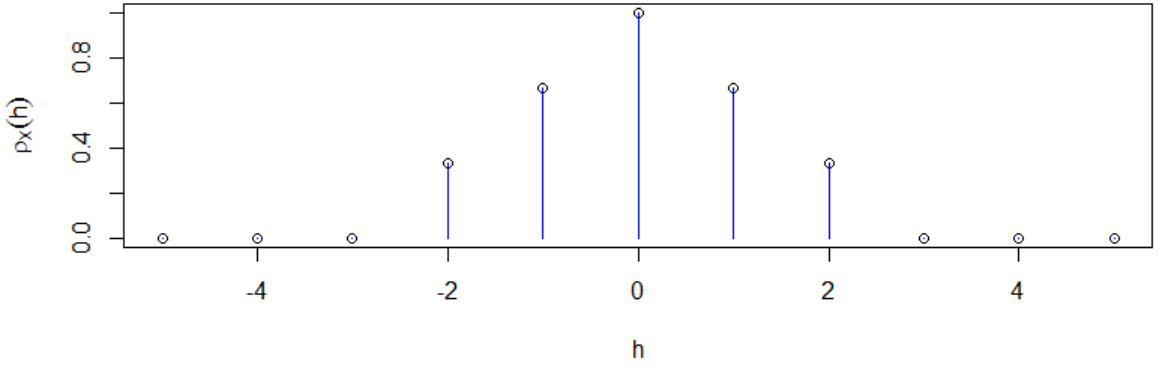


Рисунок 2.2. ACF для трех-точечного сглаживания

MA(1) процесс

Процесс скользящего среднего первого порядка (MA(1)) определяется как:

$$X_t = W_t + \theta W_{t-1}, \ t = 0, \pm 1, \pm 2, \ldots,$$

где $\{W_t\} \sim WN(0, \sigma^2)$, θ — параметр. Тогда:

$$\mu_X(t) = 0,$$
$$\gamma_X(h) = \sigma^2(1+\theta^2) I(h=0) + \theta\sigma^2 i(|h|=1),$$
$$\rho_X(h) = I(h=0) + \frac{\theta}{1+\theta^2} I(|h|=1).$$

```
rho=function(h,theta){I(h==0)+theta/(1+theta^2)*I(abs(h)==1)}
h=seq(-5,5,1); s=1:length(h); y=rho(h,.6)
plot(h,y,xlab="h",ylab=expression(rho[X](h))); segments(h[s],y[s],h[s],0,col="blue")
```

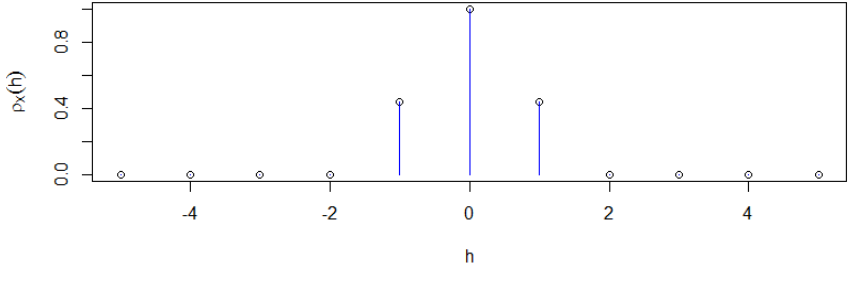


Рисунок 2.3. ACF для процесса MA(1)

AR(1) процесс

Рассмотрим следующую модел:

$$X_t = \varphi X_{t-1} + W_t,\ t = 0, \pm 1, \pm 2, \dots,$$

где $\{W_t\} \sim WN(0, \sigma^2)$ и W_t некоррелируем с X_s для $s < t$. Также предположим, что процесс $\{X_t\}$ стационарен, в параметр $\varphi \in (-1, 1)$. Тогда

$$\mu_x = \varphi \mu_x \Rightarrow \mu_x = 0.$$

Далее для $h > 0$

$$\begin{aligned}\gamma_X(h) &= \mathbf{E}\{X_t X_{t-h}\} = \mathbf{E}\{\varphi X_{t-1} X_{t-h} + W_t X_{t-h}\} \\ &= \varphi \mathbf{E}\{X_{t-1} X_{t-h}\} + 0 = \varphi \mathbf{Cov}\{X_{t-1} X_{t-h}\} \\ &= \varphi \gamma_X(h-1) = \cdots \varphi^h \gamma_X(0).\end{aligned}$$

И

$$\gamma_X(0) = \mathbf{Cov}\{\varphi X_{t-1} + W_t, \varphi X_{t-1} + W_t\} = \varphi^2 \gamma_X(0) + \sigma^2 \Rightarrow \gamma_(0) = \frac{\sigma^2}{1 - \varphi^2}.$$

Так как $\gamma_X(h) = \gamma_X(-h)$, то

$$\rho_X(h) = \varphi^{|h|}.$$

```
rho=function(h,phi){phi^(abs(h))}
h=seq(-5,5,1); s=1:length(h); y=rho(h,.3)
plot(h,y,xlab="h",ylab=expression(rho[X](h)));
segments(h[s],y[s],h[s],0,col="blue")
```

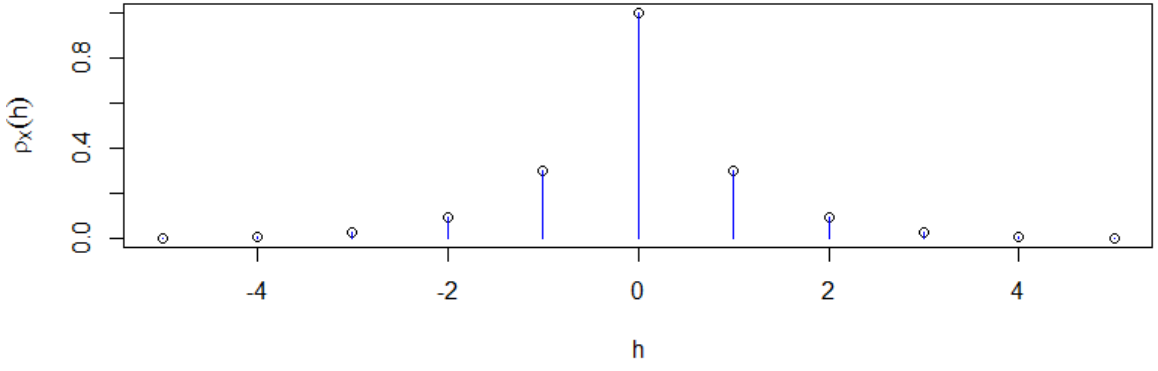


Рисунок 2.4. ACF для процесса AR(1)

Процесс случайного блуждания со смещением

В примере **??** рассматривался процесс случайного блуждания со смещением:

$$X_t = \delta t + \sum_{j=1}^{t} W_j, \ t = 1, 2, \ldots,$$

где где $\{W_t\} \sim WN(0, \sigma^2)$. Тогда

$$\mu_X(t) = \mathbf{E}\{X_t\} = \delta t.$$

В общем случае, когда δ не равно нулю, то процесс $\{X_t\}$ не является стационарным, поскольку его математическое ожидание не константа.

Далее, при $\delta = 0$:

$$\begin{aligned}\gamma_X(t+h, t) &= \mathbf{Cov}\left\{\sum_{j=1}^{t+h} W_j, \sum_{j=1}^{t} W_j\right\} \\ &= \min\{t+h, t\}\sigma^2,\end{aligned}$$

и снова, автоковариационная функция зависит от t. Таким образом, процесс $\{X_t\}$ не стационарный при любом δ.

Процесс скользящего среднего порядка q MA(q)

Процесс $\{X_t\}$ называется *процессом скользящего среднего порядка q MA(q)*, если:

$$X_t = W_t + \theta_1 W_{t-1} + \ldots + \theta_q W_{t-q}, \tag{2.2}$$

где $\{W_t\} \sim WN(0, \sigma^2)$ и $\theta_1, \ldots, \theta_q$ — параметры процесса.

Для процесса MA(q):

$$\mu_X(t) = 0,$$
$$\gamma_X(h) = \sigma^2 \sum_{j=0}^{q-|h|} \theta_j \theta_{j+|h|} I(|h| \leqslant q).$$

Лемма 2.1. *Если временной ряд $\{X_t\}$ является стационарным q-зависимым временным рядом, то есть* **Cov**$\{X_t, X_s\} = 0$ *для всех $|s-t| > q$, с нулевым средним, тогда он может быть представлен как процесс MA(q).*

2.2.2. Идентификация нестационарных временных рядов

После изучения всех вышеупомянутых стационарных временных рядов, естественно, возникнет один вопрос: какие временные ряды не являются стационарными? Нанесение данных на график всегда будет полезно для определения стационарности данных временных рядов.

Нестационарными являются:

- временные ряды с ненулевым трендом;
- временные ряды с сезонностью;
- временные ряды с непостоянной ковариацией.

Временные ряды с ненулевым трендом

Любой временной ряд с ненулевым трендом является не стационарным. Например, если

$$X_t = m_t + Y_t,$$

где m_t — тренд, Y_t — ошибки с нулевым средним, тогда

$$\mu_X(t) = m_t$$

не является константой, то есть ряд не стационарный.

Пример 2.1. Например, график реализации временного ряда $X_t = 1 + 0.05t + Y_t$, где $\{Y_t\}$ — последовательность независимых одинаково распределенных величин:

```
set.seed(100); par(mar=c(4,4,2,.5))
t=seq(1,100,1); Tt=1+.05*t; Xt=Tt+rnorm(length(t),0,2)
plot(t,Xt,xlab="t",ylab=expression(X[t])); lines(t,Tt,col="blue")
```

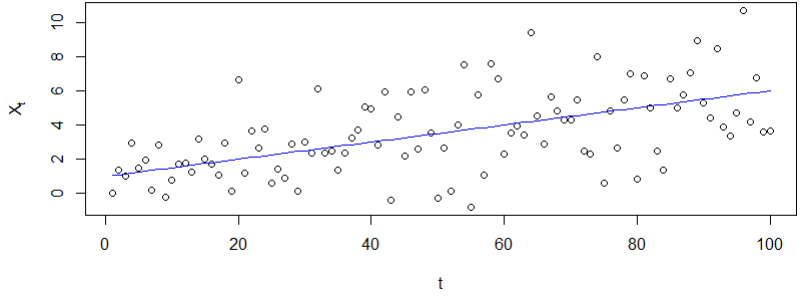


Рисунок 2.5. Временной ряд с линейным трендом

Временные ряды с сезонностью

Любой временной ряд с сезонностью является не стационарным. Например, если

$$X_t = s_t + Y_t,$$

где s_t — сезонная компонента, Y_t — ошибки с нулевым средним, тогда

$$\mu_X(t) = s_t$$

не является константой, то есть ряд не стационарный.

Пример 2.2. Например, график реализации временного ряда

$$X_t = 1 + 0.05t + 2\cos(\pi\frac{t}{6}) + 2\sin(\pi\frac{t}{3}) + Y_t,$$

где $\{Y_t\}$ — последовательность независимых одинаково распределенных величин:

```
set.seed(100); par(mar=c(4,4,2,.5)); t=seq(1,100,1); Tt=1+0.05*t;
St=2*cos(pi*t/6)+3*sin(pi*t/3); Xt=Tt+St+rnorm(length(t),0,2)
plot(t,Xt,xlab="t",ylab=expression(X[t])); lines(t,Tt+St,col="blue")
```

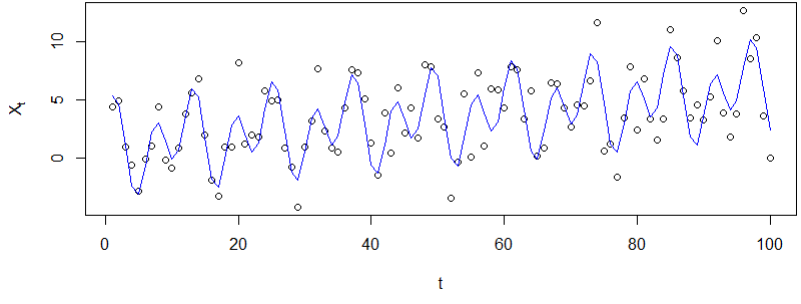


Рисунок 2.6. Временной ряд с сезонной компонентой

Временные ряды с непостоянной ковариацией

Любой временной ряд с непостоянной ковариацией является не стационарным. Например, случайное блуждание

$$\left\{ S_t = \sum_{j=1}^{t} X_t \right\},$$

где X_t независимые одинаково распределеные случайные величины из стандартного гауссовского закона $\mathcal{N}(0,1)$.

Пример 2.3.

```
set.seed(150); par(mar=c(4,4,2,.5)); t=seq(1,200,by=1); Xt1=rnorm(length(t),0,1)
plot(c(0,t),c(0,cumsum(Xt1)),type="o",col="blue",xlab="t",ylab=expression(S[t]))
```

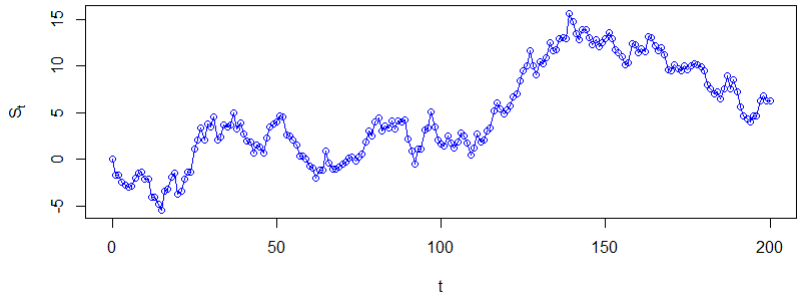


Рисунок 2.7. Временной ряд с непостоянной ковариацией

2.2.3. Выборочная ACVF

subsec:SampleACVF Для наблюдений временного ряда $x_1, \ldots, x_n$ *выборочным средним* называется

$$\bar{x} = \frac{1}{n}\sum_{t=1}^{n} x_t.$$

Выборочной автоковариационной функцией (*выборочная ACVF*) называется функция:

$$\hat{\gamma}_X(h) = \frac{1}{n}\sum_{t=1}^{n-|h|} \left(x_{t+|h|-\bar{x}}\right)\left(x_{t-\bar{x}}\right), \quad -n < h < n, \tag{2.3}$$

Это гарантирует, что выборочнная ковариационная матрица

$$\hat{\Gamma}_n = |\hat{\gamma}_X(i-j)|_{i,j=1}^{n}$$

неотрицательно определена.

Выборочной автокорреляционной функцией (*выборочная ACF*) называется функция:

$$\hat{\rho}_X(h) = \frac{\hat{\gamma}_X(h)}{\hat{\gamma}_X(0)}. \tag{2.4}$$

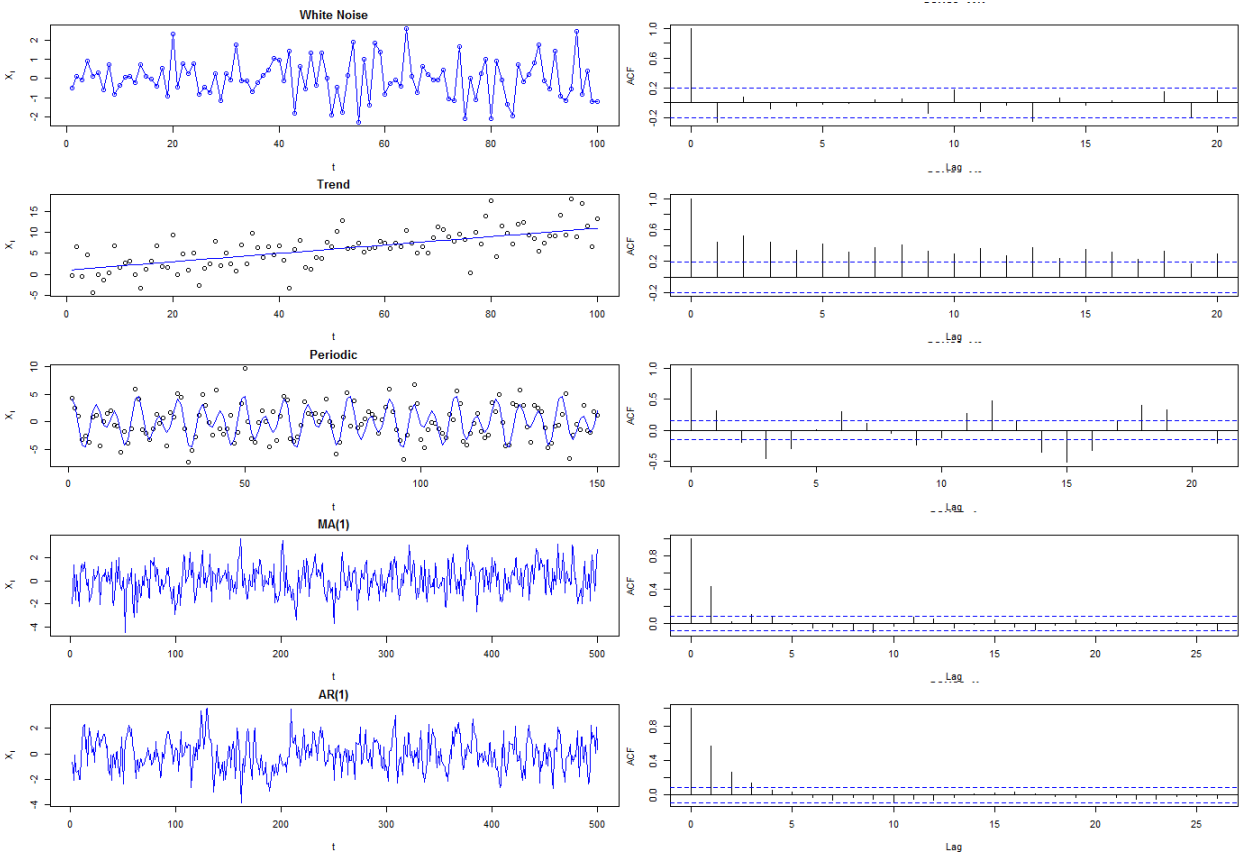
Выборочная ACF помогает распознать много типов (даже не стационарных) временных рядов.

2.2.4. «Гид»

Временной ряд:	Выборочная ACF
Белый шум	Ноль для $\|h\| > 0$
Тренд	Медленное убывание
Периодическй	Периодическая
MA(q)	Ноль для $\|h\| > q$
AR(1)	Убывание к нулю по экспоненте

```
set.seed(100);
par(mfrow=c(5,2))
par(mar=c(4,4,2,.5))
    #White Noise
WN=rnorm(100,0,1);
plot(1:n,WN,type="o",col="blue",main="White Noise",ylab=expression(X[t]),xlab="t");
acf(WN)
    #Trend
t=seq(1,100,1);
Tt=1+.1*t;
Xt=Tt+rnorm(length(t),0,4)
plot(t,Xt,xlab="t",ylab=expression(X[t]),main="Trend")
lines(t,Tt,col="blue")
acf(Xt)
    #Periodic
t=seq(1,150,1)
St=2*cos(pi*t/5)+3*sin(pi*t/3)
Xt=St+rnorm(length(t),0,2)
plot(t,Xt,xlab="t",ylab=expression(X[t]), main="Periodic")
lines(t,St,col="blue")
acf(Xt)
```

```
    #MA(1)
w = rnorm(550,0,1)
v = filter(w, sides=1, c(1,.6))[-(1:50)]
plot.ts(v, main="MA(1)",col="blue",ylab=expression(X[t]),xlab="t")
acf(v)
    #AR(1)
w = rnorm(550,0,1)
x = filter(w, filter=c(.6), method="recursive")[-(1:50)]
plot.ts(x, main="AR(1)",col="blue",ylab=expression(X[t]),xlab="t")
acf(x)
```


White Noise
Trend
Periodic
MA(1)
AR(1)
X_t
t
ACF
Lag

2.2.5. Выводы

Типичная процедура анализа временного ряда можно описать как последовательность следующих действий.

1) Графически изобразить временной ряд. По графику определить наличие:
   - тренда,
   - сезонной компоненты,
   - скачкообразных изменений,
   - выбросов.
2) Преобразовать данные так, чтобы ряд остатков стал **стационарным**.
   (a) Оценить и выделить m_t, s_t.
   (b) Осуществить дифференцирование.
   (c) Осуществить нелинейные преобразования $(\log, \sqrt{\cdot})$.
3) Осуществить подгонку модели к остаткам.

В случае, если

- $X_t = \beta_0 + \beta_1 t + Y_t$, то
$$\nabla X_t = \beta_1 + \nabla Y_t.$$
- $X_t = \sum_{i=0}^{k} \beta_i t^i + Y_t$, то
$$\nabla^k X_t = k!\beta_k + \nabla^k Y_t,$$
где $\nabla^k X_t = \nabla(\nabla^{k-1} X_t)$ и $\nabla^1 X_t = \nabla X_t$.
- $X_t = m_t + s_t + Y_t$ и s_t имеет период d (то есть $s_t = s_{t-d}$ для всех t), то
$$\nabla_d X_t = m_t - m_{t-d} - \nabla_d Y_t.$$

Здесь ∇ — оператор дифференцирования («первая производная»):

$$\nabla X_t = \frac{X_t - X_{t-1}}{t - (t-1)} = X_t - X_{t-1} = (1 - B)X_t,$$

где $BX_t = X_{t-1}$; и ∇_d — оператор дифференцирования по лагу d:

$$\nabla_d X_t = X_t - X_{t-d} = (1 - B^d)X_t,$$

где B^d —оператор B применяется d раз: $B^d X_t = B(B^{d-1} X_t) = X_{t-d}$.

2.3. Линейные процессы

Каждый стационарный процесс второго порядка является

- либо линейным процессом,
- либо может быть преобразован в линейный процесс путем вычитания детерминированного компонента, который будет обсуждаться позже.

Временной ряд $\{X_t\}$ называется *линейным процессом*, если он представим в виде

$$X_t = \mu + \sum_{j=-\infty}^{\infty} \psi_j W_{t-j} = \mu + \psi(B) W_t, \tag{3.1}$$

для всех t, где

- $\{W_t\} \sim WN(0, \sigma^2)$,
- μ — константа,
- $\{\psi_j\}$ — последовательность постоянных чисел, такая, что $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$,
- $\psi(B)$ — оператор:

$$\psi(B) = \sum_{j=-\infty}^{\infty} \psi_j B^j.$$

Заметим, что условие $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$ гарантирует, что определение X_t имеет смысл, то есть $|X_t| < \infty$ почти наверное. Так как $\mathbf{E}\{|W_t|\} \leqslant \sigma$ для всех t и

$$\mathbf{P}\{|X_t| \geqslant \alpha\} \leqslant \frac{1}{\alpha}\mathbf{E}\{|X_t|\} \leqslant \frac{1}{\alpha}\left(|\mu| + \sum_{j=-\infty}^{\infty} |\psi_j|\mathbf{E}\{|W_{t-j}|\}\right)$$
$$\leqslant \frac{1}{\alpha}\left(|\mu| + \sigma \sum_{j=-\infty}^{\infty} |\psi_j|\}\right) \to 0 \text{ при } \alpha \to \infty.$$

Теорема 3.1 (Рица-Фишера, критерий Коши). *Последовательность X_n сходится в среднеквадратическом смысле (то есть $\mathbf{E}\{X_n - X\} \to 0$, $n \to \infty$) тогда и только тогда*

$$\lim_{m,n\to\infty} \mathbf{E}\left\{(X_n - X_m)^2\right\} = 0.$$

Следствие 3.1.1. *Если для линейного процесса $X_t = \sum_{j=-\infty}^{\infty} \psi_j W_{t-j}$ выполняется $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$, то он сходится в среднеквадратическом смысле.*

Доказательство. Обозначим $S_n = \sum_{j=-n}^{n} \psi_j W_{t-j}$, тогда

$$\mathbf{E}\left\{(S_m - S_n)^2\right\} = \mathbf{E}\left\{\left(\sum_{m\leqslant|j|\leqslant n} \psi_j W_{t-j}\right)^2\right\}$$
$$= \sum_{m\leqslant|j|\leqslant n} \psi_j^2\sigma^2 \leqslant \sigma^2\left(\sum_{m\leqslant|j|\leqslant n} |\psi_j|\right)^2 \to 0 \text{ при } m,n \to \infty.$$

■

Следствие 3.1.2. *Линейный процесс* $\{X_t\}$, *определенный как (3.1), является стационарным с*

$$\mu_X = \mu \tag{3.2}$$

$$\gamma_X(h) = \sigma^2 \sum_{j=-\infty}^{\infty} \psi_{j+h}\psi_j. \tag{3.3}$$

Доказательство. Уравнение (3.2) доказывается очевидно.
Для уравнения (3.3) имеем:

$$\gamma_X(H) = \mathbf{E}\left\{\left(\sum_{j=-\infty}^{\infty} \psi_j W_{t+h-j}\right)\left(\sum_{j=-\infty}^{\infty} \psi_j W_{t-j}\right)\right\}$$

$$= \sum_{j=-\infty}^{\infty}\sum_{k=-\infty}^{\infty} \psi_j\psi_k \mathbf{E}\{W_{t+h-j}W_{t-k}\} = \sum_{j=-\infty}^{\infty}\sum_{k=-\infty}^{\infty} \psi_j\psi_k\gamma_W(h-j+k)$$

$$= \sum_{j=-\infty}^{\infty}\sum_{k=-\infty}^{\infty} \psi_j\psi_k I(k=j-h)\sigma^2 = \sigma^2\sum_{j=-\infty}^{\infty} \psi_j\psi_{j-h} = \sigma^2\sum_{j=-\infty}^{\infty} \psi_{j+h}\psi_j$$

■

Следствие 3.1.3. *Если* $\{Y_t\}$ *стационарный временной ряд с нулевым математическим ожидщанием и ковариационной функцией* γ_Y, *то при* $\sum_{j=-\infty}^{\infty}|\psi_j| < \infty$ *временной ряд*

$$X_t = \sum_{j=-\infty}^{\infty} \psi_j Y_{t-j}$$

является стационарным с нулевым математическим ожиданием и ковариационной функцией

$$\gamma_X(h) = \sum_{j=-\infty}^{\infty}\sum_{k=-\infty}^{\infty} \psi_j\psi_k\gamma_Y(h-j+k).$$

Можно легко показать, что белый шум, MA(1), MA(q), MA(∞), AR(1) — линейные процессы.

- Белый шум: выбрем μ и $\psi_j = I(j = 0)$, тогда

$$X_t = \mu + \sum_{j=-\infty}^{\infty} \psi_j W_{t-j} = \mu + W_t \sim WN(\mu, \sigma_2).$$

- MA(1): выбрем $\mu = 0$ и $\psi_j = I(j = 0) + \theta I(j = 1)$, тогда

$$X_t = \mu + \sum_{j=-\infty}^{\infty} \psi_j W_{t-j} = W_t + \theta W_{t-1}.$$

- AR(1): выбрем $\mu = 0$ и $\psi_j = \varphi^j I(j \geqslant 01)$, тогда

$$X_t = \mu + \sum_{j=-\infty}^{\infty} \psi_j W_{t-j} = \sum_{j=0}^{\infty} \varphi^j W_{t-j} = W_t + \varphi \sum_{j=0}^{\infty} \varphi^j W_{t-1-j} = W_t + \varphi X_{t-1}.$$

- MA(q): выбрем $\mu = 0$ и $\psi_j = I(j = 0) + \sum_{k=1}^{q} \theta_k I(j = k)$, тогда

$$X_t = \mu + \sum_{j=-\infty}^{\infty} \psi_j W_{t-j} = W_t + \theta_1 W_{t-1} + \ldots \theta_k W_{t-k}.$$

- MA(∞): выбрем $\mu = 0$ и $\psi_j = I(j = 0) + \sum_{k=1}^{\infty} \theta_k I(j = k)$, тогда

$$X_t = \mu + \sum_{j=-\infty}^{\infty} \psi_j W_{t-j} = \sum_{j=0}^{\infty} \theta_k W_{t-k}.$$

Глава 3

Процесс авторегрессии и скользящего среднего ARMA

3.1. Модель авторегрессии AR(p)
3.2. Модель скользящего среднего MA(q)
3.3. Модель авторегрессии и скользящего среднего ARMA(p,q)
3.4. Этапы построения моделей ARMA

3.1. Модель авторегрессии AR(p)

3.1.1. Определение модели AR(p)
3.1.2. Условия стационарности AR(p)
3.1.3. Вероятностные характеристики процесса AR(p)
3.1.4. Модель авторегрессии первого порядка AR(1)

3.1.1. Определение модели AR(p)

Временной ряд $\{X_t\}$ описывается моделью *авторегрессии порядка* p ($p \geq 1$) (обозначается $AR(p)$), если удовлетворяет стохастическому разностному уравнению вида

$$X_t = \varphi_0 + \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \ldots + \varphi_p X_{t-p} + W_t, \quad t = 1, 2, \ldots, T, \tag{1.1}$$

где

- φ_0 - свободный член,
- $\{\varphi_i\}$ ($i = 1, 2, \ldots, p$) — коэффициенты авторегрессии,
- $X_{1-p}, X_{2-p}, \ldots, X_0$ — начальные значения временного ряда,
- $\{W_t\} \sim WN(0, \sigma_2)$ — случайные ошибки наблюдения, или инновационный процесс белого шума.

Формула (1.1) допускает представление

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \ldots - \varphi_p X_{t-p} = \varphi_0 + W_t,$$

откуда следует

$$\varphi(B) X_t = \varphi_0 + W_t. \tag{1.2}$$

Относительно инновационного процесса дополнительно предполагается, что

$$\mathbf{Cov}\{X_{t-l}, W_t\} = 0, \quad l \geq 1, \ t = 1, 2, \ldots, T. \tag{1.3}$$

3.1.2. Условия стационарности AR(p)

Соотношение (1.1) не всегда описывает стационарный временной ряд, поэтому для модели $AR(p)$ формулируются специальные *условия стационарности* в виде ограничений на корни характеристического уравнения, соответствующего стохастическому разностному уравнению (1.1).

Условие стационарности для модели AR(p) (форма 1): корни характеристического уравнения

$$\lambda^p - \varphi_1\lambda^{p-1} - \ldots - \varphi_{p-1}\lambda - \varphi_p = 0 \tag{1.4}$$

лежат внутри единичного комплексного круга, записывается следующим образом:

$$|\lambda_i| < 1,\ i = 1, \ldots, p. \tag{1.5}$$

Условие стационарности для модели AR(p) (форма 2): корни характеристического уравнения

$$1 - \varphi_1 z - \varphi_2 z^2 - \ldots - \varphi_p z^p = 0 \tag{1.6}$$

лежат вне единичного комплексного круга, записывается в виде

$$|z_i| > 1,\ i = 1, \ldots, p. \tag{1.7}$$

Если эти условия нарушаются, то временной ряд $\{X_t\}$ не является стационарным. Если модель AR(p) удовлетворяет условию стационарности, то

$$1 - \varphi_1 - \varphi_2 - \ldots - \varphi_p > 0. \tag{1.8}$$

3.1.3. Вероятностные характеристики процесса AR(p)

Если временной ряд описывается $\{X_t\}$ моделью AR(p) ($p \geqslant 1$) и выполняются условия (1.3), (1.5), то временной ряд является стационарным, то есть его вероятностные характеристики не зависят от времени и вычисляются по следующим формулам:

- математическое ожидание:
$$\mu_X = \mathbf{E}\{X_t\} = \frac{\varphi_0}{1 - \varphi_1 - \ldots - \varphi_p};$$
- дисперсия:
$$\mathbf{D}\{X_t\} = \gamma_X(0) = \varphi_1\gamma_X(1) + \varphi_p\gamma_X(p) + \ldots + \varphi_p\gamma_X(p) + \sigma^2;$$
- автоковариационная функция:
$$\gamma_X(h) = \varphi_1\gamma_X(h-1) + \varphi_2\gamma_X(h-2) + \ldots + \varphi_p\gamma_X(h-p),\ h \geqslant 1;$$
- автокорреляционная функция:
$$\rho_X(h) = \frac{\gamma_X(h)}{\gamma_X(0)}.$$

3.1.4. Модель авторегрессии первого порядка AR(1)

Если в формуле (1.1) параметр авторегрессии положить $p = 1$, то временной ряд будет описываться моделью *авторегрессии первого порядка* AR(1):

$$X_t = \varphi_0 + \varphi_1 X_{t-1} + W_t,\ t = 1, \ldots, T, \tag{1.9}$$

где

- φ_0 — свободный член;
- φ_1 — коэффициент авторегрессии;
- X_0 — начальное значение временного ряда;
- $\{W_t\} \sim WN(0, \sigma^2)$ — белый шум.

Временной ряд AR(1) можно записать в эквивалентной форме:

$$X_t - \varphi_1 X_{t-1} = \varphi_0 + W_t,$$
$$(1 - \varphi_1 B) X_t = \varphi_0 + W_t.$$

Характеристическое уравнение для AR(1) принимает вид:

$$\lambda - \varphi_1 = 0,$$

откуда следует условие стационарности для AR(1):

$$|\lambda_1| = |\varphi_1| < 1. \tag{1.10}$$

Так же временной ряд (1.9) можно представить в виде линейного процесса:

$$X_t = \frac{\varphi_0}{1 - \varphi_1} + \sum_{i=0}^{\infty} \varphi_1^i W_{t-i}.$$

Вероятностные характеристики процесса AR(1)

Если временной ряд описывается $\{X_t\}$ моделью AR(1) и выполняются условия $|\varphi_0| < 1$, то временной ряд является стационарным, то есть его вероятностные характеристики не зависят от времени и вычисляются по следующим формулам:

- математическое ожидание:
$$\mu_X = \mathbf{E}\{X_t\} = \frac{\varphi_0}{1-\varphi_1};$$
- дисперсия:
$$\mathbf{D}\{X_t\} = \gamma_X(0) = \frac{\sigma^2}{1-\varphi_1^2};$$
- автоковариационная функция:
$$\gamma_X(h) = \varphi_1^h \gamma_X(0),\ h \geqslant 1;$$
- автокорреляционная функция:
$$\rho_X(h) = \varphi_1^h,\ h \geqslant 0.$$

3.2. Модель скользящего среднего MA(q)

3.2.1. Определением модели MA(q)
3.2.2. Условия обратимости
3.2.3. Вероятностные характеристики процесса MA(q)

3.2.1. Определением модели MA(q)

Временной ряд $\{X_t\}$ описывается *моделью скользящего среднего порядка* $q \geq 1$ (обозначается MA(q)), если его значения формируются на основе белого шума $\{W_t\}$ по формуле

$$X_t = \mu + W_t - \theta_1 W_{t-1} - \theta_2 W_{t-2} - \ldots - \theta_q W_{t-q}, \quad t = 1, 2, \ldots, T, \tag{2.1}$$

или

$$X_t = \mu + (1 - \theta_1 B - \theta_2 B^2 - \ldots - \theta_q B^q) W_t = \mu + \theta(B) W_t$$

где

- μ — среднее значение временного ряда;
- $\{\theta_k\}$ $(k = 1, 2, \ldots, q)$ — коэффициенты скользящего среднего;
- $\{W_t\}$ — белый шум;
- $W_{1-q}, W_{2-q}, \ldots, W_0$ — начальные значения инновационного процесса.

1) Заметим, что временные ряды вида (2.1) стационарны для любых вещественных значений параметров $\{\theta_k\}$ $(k = 1, 2, \ldots, q)$. Таким образом, в отличие от моделей авторегрессии, модели скользящего среднего не требуют каких-либо дополнительных предположений (условий стационарности) для того, чтобы описываемый ими временной ряд был стационарным.

2) Любая модель $AR(p)$ $(1 \leq p < \infty)$ может быть представлена в виде модели скользящего среднего бесконечного порядка MA(∞). Оказывается, что при выполнении так называемых «*условий обратимости*» возможно и обратное представление, т.е. представление модели MA(q) $(1 \leq q < \infty)$ в виде стационарной модели авторегрессии бесконечного порядка AR(∞).

3.2.2. Условия обратимости

Условия обратимости для модели MA(q), как и условия стационарности для модели AR(p), формулируются в виде ограничений на корни соответствующих характеристических уравнений.

Условие обратимости для модели MA(q) (форма 1): корни характеристического уравнения

$$\lambda^q - \theta_1\lambda^{q-1} - \ldots - \theta_{q-1}\lambda - \theta_p = 0 \tag{2.2}$$

лежат внутри единичного комплексного круга, записывается

$$|\lambda_i| < 1,\ i = 1, \ldots, p. \tag{2.3}$$

Условие обратимости для модели MA(q) (форма 2): корни характеристического уравнения

$$1 - \theta_1 z - \theta_2 z^2 - \ldots - \theta_q z^q = 0 \tag{2.4}$$

лежат вне единичного комплексного круга, записывается ($z_i = 1/\lambda_l$)

$$|z_i| > 1,\ i = 1, \ldots, q. \tag{2.5}$$

Если для модели MA(q) выполняется условие обратимости, то

$$1 - \theta_1 - \theta_2 - \ldots - \theta_q > 0. \tag{2.6}$$

3.2.3. Вероятностные характеристики процесса MA(q)

Если временной ряд описывается $\{X_t\}$ моделью MA(q) ($q \geqslant 1$), то временной ряд является стационарным, то есть его вероятностные характеристики не зависят от времени и вычисляются по следующим формулам:

- математическое ожидание:
$$\mu_X = \mathbf{E}\{X_t\} = \mu;$$
- дисперсия:
$$\mathbf{D}\{X_t\} = \gamma_X(0) = \left(1 + \theta_1^2 + \theta_2^2 + \ldots + \theta_q^2\right)\sigma^2;$$
- автоковариационная функция:
$$\gamma_X(h) = \begin{cases} \left(-\theta_h + \theta_1\theta_{h+1} + \ldots + \theta_{q-h}\theta_q\right)\sigma^2, & h \leqslant q \\ 0, & h > q \end{cases};$$
- автокорреляционная функция:
$$\rho_X(h) = \frac{\gamma_X(h)}{\gamma_X(0)} = \begin{cases} \frac{-\theta_h + \theta_1\theta_{h+1} + \ldots + \theta_{q-h}\theta_q}{1 + \theta_1^2 + \theta_2^2 + \ldots + \theta_q^2}, & h \leqslant q \\ 0, & h > q \end{cases}.$$

3.3. Модель авторегрессии и скользящего среднего ARMA(p,q)

3.3.1. Определение модели ARMA(p,q)
3.3.2. Условия стационарности и обратимости
3.3.3. Модель авторегрессии и скользящего среднего ARMA(1,1)

3.3.1. Определение модели ARMA(p,q)

Временной ряд $\{x_t\}$ описывается моделью *авторегрессии и скользящего среднего порядка p и q* (обозначается ARMA(p,q) $p, q \geq 1$), если

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \ldots - \varphi_p X_{t-p} = \varphi_0 + W_t - \theta_1 W_{t-1} - \theta_2 W_{t-2} - \ldots - \theta_q x_{t-q},\ t = 1, 2, \ldots, T,$$

или

$$\varphi(B) X_t = \varphi_0 + \theta(B) W_t, \tag{3.1}$$

где

- $\{\varphi_i\}$ $(i = 0, 1, 2, \ldots, p)$, $\{\theta_k\}$ $(1, 2, \ldots, q)$ — параметры модели;
- X_{1-p}, X_{2-p},..., X_0, W_{1-q}, W_{2-q}, ..., W_0 — начальные условия;
- $\varphi(B), \theta(B)$ — полиномы:

$$\varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \ldots - \varphi_p B^p,$$
$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \ldots - \theta_q B^q.$$

3.3.2. Условия стационарности и обратимости

Модель ARMA(p, q) получается как комбинация двух моделей:

- модели авторегрессии AR(p) и
- модели скользящего среднего MA(q).

Поэтому для модели ARMA(p,q)

- условия стационарности совпадают с условиями стационарности (1.4)-(1.6) для модели AR(p),
- а условия обратимости — с условиями обратимости для модели MA(q).

При выполнении условий стационарности и обратимости с учетом (2.2), (2.6) из (3.1) могут быть получены представления для ARMA(p,q) в виде моделей AR(∞) и MA(∞) соответственно:

$$x_t = \mu + \varphi^{-1}(L)\theta(L)W_t, \quad \mu = \frac{\varphi_0}{1 - \varphi_1 - \ldots - \varphi_p},$$

$$\theta^{-1}(L)\varphi(L)x_t = \mu' + W_t, \quad \mu' = \frac{\varphi_0}{1 - \theta_1 - \ldots - \theta_q}.$$

3.3.3. Модель авторегрессии и скользящего среднего ARMA(1,1)

На практике часто параметры модели $p, q \in \{0, 1, 2\}$. В частном случае, когда $p = q = 1$, получаем модель ARMA(1,1):

$$X_t - \varphi_1 X_{t-1} = \varphi_0 + W_t + \theta_1 W_{t-1},\ t = 1, 2, \ldots. \tag{3.2}$$

Условия стационарности и обратимости для модели ARMA(1,1) — это

1) $|\varphi_1| < 1$ (условие стационарности для модели AR(1)),

2) $|\theta_1| \leqslant 1$ (условие обратимости для модели MA(1)).

Если выполняются условия стационарности и обратимости, то для модели ARMA(1,1) справедливы следующие представления:

- MA(∞)-представление:

$$X_t = \frac{\varphi_0}{1 - \varphi_1} + (\varphi_1 - \theta_1) \sum_{k=1}^{\infty} \varphi_1^{k-1} W_{t-k} + W_t;$$

- AR(∞)-представление:

$$X_t = \frac{\varphi_0}{1 - \theta_1} + (\varphi_1 - \theta_1) \sum_{k=1}^{\infty} \theta_1^{k-1} W_{t-k} + W_t;$$

Вероятностные характеристики процесса ARMA(1,1)

Если временной ряд описывается $\{X_t\}$ моделью AR(1) и выполняются условия $|\varphi_0| < 1$, то временной ряд является стационарным, то есть его вероятностные характеристики не зависят от времени и вычисляются по следующим формулам:

- математическое ожидание:
$$\mu_X = \mathbf{E}\{X_t\} = \frac{\varphi_0}{1-\varphi_1};$$
- дисперсия:
$$\mathbf{D}\{X_t\} = \gamma_X(0) = \frac{1+\theta_1^2-2\theta_1\varphi_1}{1-\varphi_1^2}\sigma^2;$$
- автокорреляционная функция:
$$\rho_X(1) = \frac{(1-\varphi_1\theta_1)(\varphi_1-\theta_1)}{1+\theta_1^2-2\theta_1\varphi_1}$$
$$\rho_X(h) = \varphi_1\rho_X(h-1) = \varphi_1^{h-1}\rho_X(1),\ h>1.$$

3.4. Этапы построения моделей ARMA

3.4.1. Подход Бокса-Дженкинса
3.4.2. Методы идентификации и оценивания параметров моделей ARMA
3.4.3. Методы тестирования адекватности модели ARMA

3.4.1. Подход Бокса-Дженкинса

Процесс построение модели ARMA(p, q) для временного ряда $\{X_t\}$ $(t = 1, 2, \ldots, T)$ состоит из трех основных этапов[1]:

- идентификация модели,
- оценивание параметров,
- тестирование адекватности построенной модели

Идентификация модели предусматривает исследование стационарности временного ряда $\{X_t\}$ и установление для стационарного временного ряда $\{X_t\}$ возможного типа модели на множестве альтернатив (ARMA, AR, MA), т.е. предварительную оценку параметров p и q. В итоге для дальнейшего исследования, как правило, выбирается несколько альтернативных вариантов модели, соответствующих различным вариантам значений параметров p и q.

Если предположение о стационарности временного ряда $\{X_t\}$ не подтверждается, то устанавливается тип нестационарности и, в зависимости от установленного типа, осуществляются необходимые преобразования нестационарного временного ряда. При этом предполагается, что итоговый временной ряд должен быть стационарным. При обнаружении признаков гетероскедастичности, т.е. нестационарности по дисперсии, целесообразно осуществить соответствующее функциональное преобразование временного ряда. Например, при относительно монотонном увеличении дисперсии рекомендуется осуществить логарифмическое преобразование временного ряда. Если же временной ряд включает периоды с относительно высокой и относительно малой дисперсией, то следует рассмотреть возможность построения модели ARMA с остатками в виде ARCH или GARCH.

[1] Описываемый подход известен как подход Бокса-Дженкинса

На этапе *оценивания параметров* по временному ряду $\{X_t\}$ $(t = 1, 2, \ldots, T)$ для рассматриваемых вариантов значений p и q находятся статистические оценки параметров модели ARMA(p, q). Для этой цели могут использоваться различные методы:

- линейный (если $q = 0$),
- нелинейный (если $q \neq 0$),
- метод наименьших квадратов (МНК),
- метод максимального правдоподобия (ММП),
- метод моментов.

Тестирование адекватности основано на анализе тестовых статистик и статистической проверке гипотез относительно параметров и временного ряда остатков тестируемой модели. Адекватная модель должна обладать следующими свойствами:

1) оценки параметров модели (коэффициенты авторегрессии и/или скользящего среднего, свободный член) должны быть статистически значимыми;
2) остатки построенной модели должны быть гауссовским белым шумом.

Если для одного и того же временного ряда получено несколько вариантов статистически адекватных моделей, различающихся значениями параметров p и q, то возникает проблема выбора "наилучшего" варианта. Данная проблема решается в соответствии с *принципом экономичности модели* (*principle of parsimony*): модель должна быть наиболее простой из возможных альтернативных моделей, обеспечивающих приемлемую точность аппроксимации наблюдаемых значений временного ряда.

3.4.2. Методы идентификации и оценивания параметров моделей ARMA

Для установления свойства стационарности и определения типа модели стационарного временного ряда $\{X_t\}$ $(t = 1, 2, \ldots, T)$ выполняются следующие исследования временного ряда:

1) визуальный анализ графика временного ряда с целью выявления «признаков нестационарности»: «выбросов», структурных и сезонных изменений, зависимости среднего значения и дисперсии временного ряда от времени, указывающих на наличие временных трендов и гетероскедастичности;

2) анализ ВАКФ и ВЧАКФ, позволяющий подтвердить либо опровергнуть предположение о стационарности анализируемого временного ряда, выявить сезонные эффекты, а также указать на возможные значения параметров p и q;

3) проверка стационарности временного ряда и установление типа нестационарности с помощью статистических тестов, известных как «тесты единичного корня» (unit root tests).

3.4.3. Методы тестирования адекватности модели ARMA

Проверка статистической значимости параметров модели

Для проверки статистической значимости оценок параметров $\{\varphi_i\}$ $(i = 1, 2, \ldots, p)$, $\{\theta_k\}$ $(k = 1, 2, \ldots, q)$ модели ARMA(p, q) вида (3.1) для заданных значений параметров p и q используются тесты, основанные на t- и F-статистиках, как и в случае модели множественной линейной регрессии.

Анализ некоррелированности и одинаковой распределенности остатков

Для проверки гипотезы о том, что временной ряд остатков является белым шумом, т.е. представляет собой последовательность некоррелированных и одинаково распределенных случайных величин, используется следующие методы.

- Визуальный анализ графика остатков с целью обнаружения признаков нестационарности.
- Анализ ВАКФ с учетом ее свойств для моделей ARMA и процесса белого шума.
- Проверка гипотезы о незначимости ВАКФ для отдельных лагов $h \geq 1$, на основе асимптотического теста. В частности, в случае АКФ проверяются гипотезы

$$\mathrm{H}_0 : \rho_h = 0,$$
$$\mathrm{H}_1 : \rho_h \neq 0,\ h \in \{1, \ldots, h_{max}\}\ (h_{max} < T).$$

Известно, что

$$Ł\left\{\sqrt{T}\hat{\rho}_h | H_0\right\} \to \mathbb{N}_1(0, 1) \text{ при } T \to \infty,$$

откуда следует, что для заданного уровня значимости ε с вероятностью $1 - \varepsilon$

$$\frac{-\Phi^{-1}(1-\varepsilon)}{\sqrt{T}} < \hat{\rho}_h < \frac{\Phi^{-1}(1-\varepsilon)}{\sqrt{T}}. \tag{4.1}$$

Соотношение (4.1) определяет $(1-\varepsilon)\times 100\%$-ные доверительные границы, которые отмечаются на графике коррелограм для $\varepsilon = 0.05$. Очевидно, выход значения $\hat{\rho}_h$ за какую-либо доверительную границу свидетельствует о статистически значимой корреляции остатков для лага h.

- Проверка гипотезы об отсутствии автокорреляции значений временного ряда $\{x_t\}$ на заданном лаговом диапазоне, включающем h $(1 < h < T)$ лагов ($\mathrm{H}_0 : \rho_1 = \rho_2 = \ldots = \rho_h = 0$, $\mathrm{H}_1 : \overline{\mathrm{H}_0}$), с помощью *Q-статистики Льюнга-Бокса*[2], рассчитываемой на основании значений ВАКФ $\{\hat{\rho}_h\}$ по формуле

$$Q = T(T+2)\sum_{k=1}^{h}\frac{\hat{\rho_k}^2}{T-k}.$$

  Статистики Льюнга-Бокса (при условии, что верна нулевая гипотеза об отсутствии автокорреляции значений временного ряда, на заданном лаговом диапазоне) имеет χ^2 распределению с $\nu = h - m$ степенями свободы, где m — число AR- и MA-компонентов в построенной модели временного ряда.

  Таким образом, если $Q \geq \Delta(\varepsilon)$ (где $\Delta(\varepsilon)$ — критическое значение статистки, равное квантили уровня $(1-\varepsilon)$ χ^2 распределения с ν степенями свободы), то нулевая гипотеза об отсутствии автокорреляции отклоняется.

  Для выявления автокорреляции во временном ряде могут использоваться также другие критерии, например,

  - критерий Бреуша–Годфри для сериальной корреляции (Breusch–Godfrey test for serial correlation);
  - критерий множителей Лагранжа (Lagrange multiplier test — LM);
  - h-статистика Дарбина–Уотсона (Durbin–Wotson h-statistics) для обнаружения автокорреляции первого порядка

Заметим, что обычной статистики Дарбина-Уотсона не достаточно при анализе автокорреляции остатков в моделях, содержащих лаговые значения эндогенной переменной, поскольку она в указанных случаях проявляет смещение в пользу решения об отсутствии автокорреляции ошибок.

[2] Liung G., Box G. On a measure of lack of fit in time series models// Biometrica. № 65. 1978. P. 297-303.

Наличие автокорреляции остатков может быть следствием как неадекватности модели (например, вследствие ошибок в определении параметров p и q), так и сезонных изменений временного ряда. В последнем случае возникает потребность в построении *сезонной ARMA-модели* .

Проверка «гауссовости» остатков

Свойство «гауссовости» распределения остатков особенно важно при тестировании моделей по коротким временным рядам. В случае достаточно длинных временных рядов используемые при тестировании адекватности моделей ARMA статистики имеют в асимптотике при $T \to \infty$ требуемые модельные законы распределения, и поэтому несущественные нарушения нормальности распределения остатков не являются критическими для применения соответствующих тестов. Для проверки гипотезы H_0 о нормальном распределении остатков могут использоваться различные тесты, например, критерии согласия Пирсона, Колмогорова-Смирнова, Крамера-Мизеса-Смирнова, тест Жака-Бера (*Jarque-Bera's-JB test*) и др.

Тест Жака-Бера основан на проверке статистической значимости расхождения фактических значений коэффициентов асимметрии и эксцесса, рассчитанных для временного ряда остатков, и ожидаемых для нормального распределения значений данных характеристик . Тестовая статистика для него вычисляется по формуле

$$JB = \frac{T-m}{6}\left(S^2 + \frac{K^2}{4}\right),$$

где S и K — оценки коэффициентов асимметрии и эксцесса соответственно для ряда остатков, m — число оцениваемых параметров в тестируемой модели временного ряда. Если гипотеза H_0 верна, то статистика *JB* имеет χ^2-квадрат распределение с двумя степенями свободы.

Выбор модели на основе принципа экономичности

Требование простоты модели предполагает, что из двух моделей, признанных по результатам тестирования на одном и том же наборе данных адекватными, лучшей считается модель с меньшим числом параметров, т.е. с меньшими значениями p и q. При этом *сумма квадратов остатков (sum of squared residuals – RSS)*, очевидно, также должна учитываться, как характеристика точности аппроксимации наблюдаемых значений временного ряда с помощью построенной модели.

Для выбора наилучшей в указанном смысле модели используются так называемые *информационные критерии* Акаике (*Akaike information criterion — AIC*), Шварца (*Schwarz criterion — SC*) и некоторые другие. Статистики критериев Акаике и Шварца определяются по формулам:

$$AIC = \ln\left(\frac{RSS}{T}\right) + \frac{2m}{T},$$
$$SC = \ln\left(\frac{RSS}{T}\right) + \frac{m}{T}\ln(T),$$

где m – число оцениваемых параметров, т. е. $m = p + q + \delta$ ($\delta = 1$, если используется модель со свободным членом, $\delta = 0$ в противном случае).

Согласно критериям Акаике и Шварца лучшей модели соответствуют меньшие значения статистик *AIC* и *SBC*. Следует иметь в виду, что при $T \to \infty$ критерий Акаике демонстрирует «смещение» в пользу «перепараметризованных» (т.е. «неэкономных» моделей), в то время как критерий Шварца остается в данном случае состоятельным.

Заметим также, что если p, q принимают неоправданно большие значения, т.е. построенная модель ARMA(p, q) не является «экономной», то это может быть причиной эффектов мультиколлинеарности, например, чувствительности параметров модели к исключению отдельных AR- или MA-компонентов.

Глава 4

Анализ нестационарных временных рядов

4.1. Модели временных рядов с детерминированными и стохастическими трендами
4.2. Методы построения моделей нестационарных временных рядов

4.1. Модели временных рядов с детерминированными и стохастическими трендами

4.1.1. Типы нестационарности
4.1.2. Модели временных рядов с детерминированным трендом
4.1.3. Модель авторегрессии и интегрированного скользящего среднего
4.1.4. Процессы «единичного корня»
4.1.5. «Взрывные» случайные процессы

4.1.1. Типы нестационарности

Различают два типа нестационарных временных рядов:

- временные ряды, нестационарные по среднему значению,
- и временные ряды, нестационарные по дисперсии.

Временной ряд $\{X_t\}$ является

- *нестационарным по среднему значению*, если его математическое ожидание зависит от времени,
- и *нестационарным по дисперсии*, если его дисперсия зависит от времени (т.е. имеет место *безусловная гетероскедастичность*):

$$\mathbf{E}\{X_t\} = \mu_X(t), \quad \mathbf{D}\{X_t\} = \sigma_X^2(t), \quad t \geq 1. \tag{1.1}$$

Для описания временных рядов, нестационарных по среднему значению, используется два основных класса моделей:

- *модели с детерминированными трендами*, т.е. модели с трендом в виде детерминированной функции времени,
- и *модели со стохастическими трендами*, среди которых различают:
  - *интегрированные временные ряды*, описываемые моделью ARIMA,
  - «*процессы единичного корня*»
  - и «*взрывные процессы*».

Заметим, что временные ряды со стохастическими трендами являются нестационарными и по дисперсии.

4.1.2. Модели временных рядов с детерминированным трендом

Модели временных рядов с детерминированным трендом представляются в виде

$$X_t = f(t, \beta) + W_t, \quad t = 1, 2, \ldots, \tag{1.2}$$

где

- $\{W_t\} \sim WN(0; \sigma^2)$ — белый шум;
- $\mu_X(t) = \mathbf{E}X_t = f(t, \beta)$ — математическое ожидание временного ряда, определяемое детерминированной функцией тренда $f(t, \beta)$, зависящей от времени t и заданной с точностью до параметров β.

Принято считать, что детерминированные временные тренды формируются под действием *долговременных факторов* и отражают *основную тенденцию изменения* (или *долгосрочное среднее значение*) временного ряда.

Часто предполагается, что функция тренда $f(t, \beta)$ $(\beta = (\beta_i) \in^{m+1})$ является полиномом степени $m \geq 1$, т.е. имеет место *полиномиальный тренд* вида

$$f(t, \beta) = \sum_{i=0}^{m} \beta_i t^i. \tag{1.3}$$

Пример 1.1. *Модель с линейным трендом* получается из (1.1), (4.2) при $m = 1$, $t = 1, 2, \ldots, T$:

$$X_t = \beta_0 + \beta_1 t + W_t. \tag{1.4}$$

Пример 1.2. *Модель с квадратичным трендом* $(m = 2)$:

$$X_t = \beta_0 + \beta_1 t + \beta_2 t^2 + W_t.$$

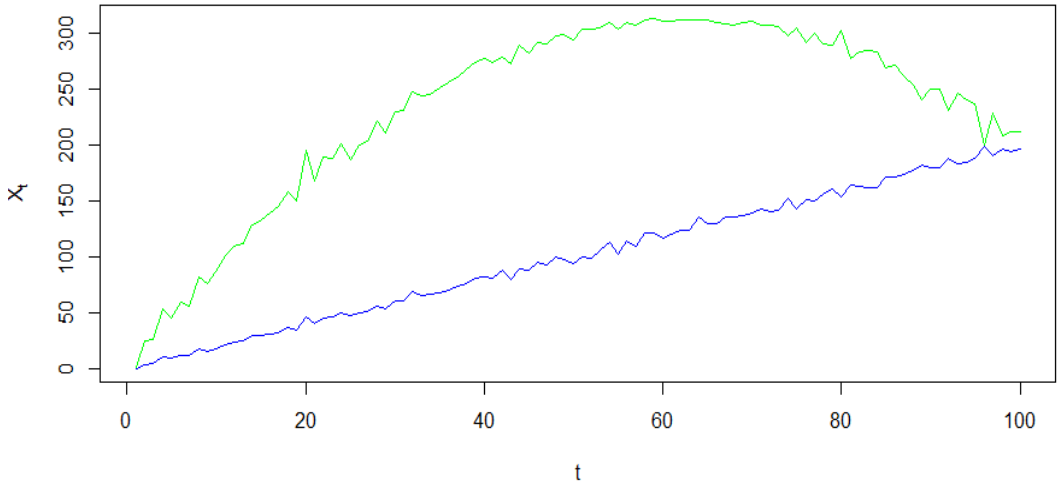


Рисунок 4.1. Модели с квадратичным (верхняя линия) и линейным трендом (нижняя линия)

На рис. 4.1 приведены графики временных рядов, описываемых моделями с детерминированными линейным ($X_t = 2t + W_t$) и квадратичным ($X_t = 5t - 0.02t^2 + W_t$) трендами.

```
set.seed(100); par(mar=c(4,4,2,.5))
t=seq(1,100,1)
Tt=2 * t +rnorm(length(t),0,3)
Xt=5*Tt - 0.02 * Tt*Tt+rnorm(length(t),0,3)
plot(t,Xt,xlab="t",ylab=expression(X[t]), type = 'l', col="green");
lines(t,Tt,col="blue")
```

Пример 1.3. *Модель со степенным трендом*:

$$X_t = \beta_0 + \beta_1 t^{\beta_2} + W_t.$$

Пример 1.4. *Модель с экспоненциальным трендом*:

$$X_t = \beta_0 + \beta_1 \exp(\beta_2 t) + W_t.$$

Пример 1.5. *Модель с логарифмическим трендом*:

$$X_t = \beta_0 + \beta_1 \ln(t) + W_t.$$

На рис. 4.2 приведены графики временных рядов, описываемых моделями с детерминированными трендами:

- со степенным трендом:
$$X_t = 20 - 2\sqrt{t} + W_t;$$
- с экпоненциальным трендом:
$$X_t = 1 + 0.001 \exp(0.1t) + W_t;$$
- с логарифмическим трендом:
$$X_t = 1 + 2.5 \log(t+1) + W_t;$$

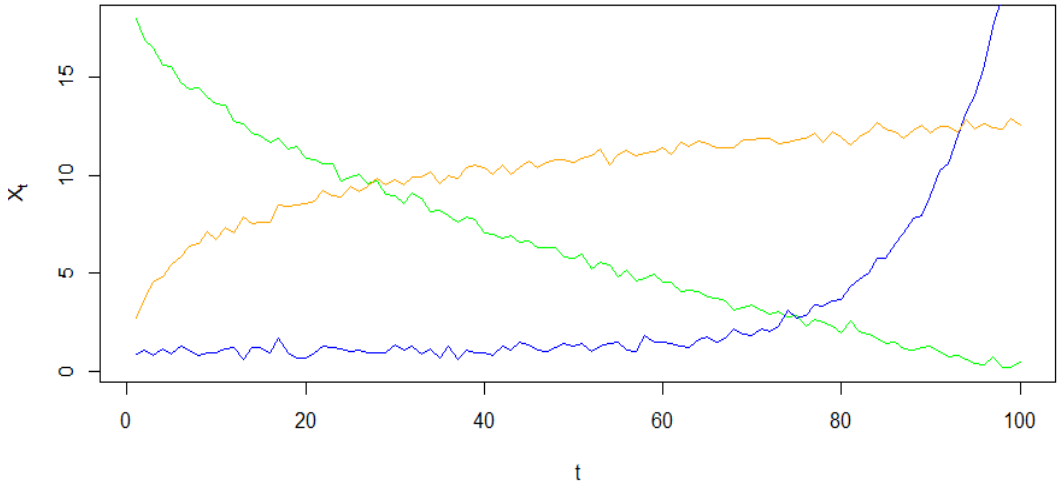


Рисунок 4.2. Модели детерминированными трендами: синяя линия - с экспоненциальным трендом; зеленая линия - со степенным трендом; оранжевая линия - с логарифмическим трендом;

```
set.seed(100); par(mar=c(4,4,2,.5))
t=seq(1,100,1); step=20 -2 * sqrt(t) +rnorm(length(t),0,0.25)
expTS = 1 + 0.001 * exp(0.1 * t) +rnorm(length(t),0,0.25)
logTS = 1 + 2.5 * log(t+1) +rnorm(length(t),0,0.25)
plot(t,step,xlab="t",ylab=expression(X[t]), type = 'l', col="green");
lines(t,expTS,col="blue"); lines(t,logTS,col="orange")
```

Предположение о детерминированном типе тренда во временных рядах часто используется на практике, особенно в экономических исследованиях. Однако данное предположение может быть оправдано, если выполняются, по крайней мере, два условия:

1) наблюдается тенденция возврата значений временного ряда к долгосрочному среднему значению, определяемому временным трендом, т.е. относительно регулярное пересечение линии тренда траекторией временного ряда;

2) шоковые воздействия на процессы, порождающие временные ряды, не вызывают каких-либо долгосрочных эффектов.

Для оценивания параметров функции тренда, т.е. для *выделения тренда,* используется (в зависимости от вида функции тренда) линейный либо нелинейный метод наименьших квадратов (МНК), а для тестирования адекватности — стандартный набор тестов и тестовых статистик.

Так, например, для модели с полиномиальным трендом (4.2), (1.3) с помощью замены переменных $z_{ti} \equiv t^i$ $(i = 0, 1, 2, \ldots, m,\ m \geq 1)$ может быть получено представление в виде модели множественной линейной регрессии:

$$X_t = \sum_{i=0}^{m} \beta_i z_{ti} + W_t, \quad t = 1, 2, \ldots, \tag{1.5}$$

для построения которой могут использоваться методы регрессионного анализа (см. гл. **??**).

Нестационарные временные ряды, которые после выделения детерминированного тренда с помощью МНК приводят к стационарному ряду остатков, часто называют «*стационарными относительно тренда*» (*trend stationary time series*). Модели данного класса нестационарных временных рядов называются *TS*-моделями.

4.1.3. Модель авторегрессии и интегрированного скользящего среднего

Модели с детерминированными трендами не годятся для описания временных рядов, если для них характерны такие особенности, как[1]:

- *чередование периодов относительного подъема и снижения* при отсутствии тенденции возврата к долгосрочному среднему значению, т.е. изменения значений временного ряда типа *случайного блуждания*;
- *сохранение эффекта после устранения причины*, т.е. *высокая степень инерционности*, проявляющаяся в том, что последствия каких-либо воздействий на процессы проявляют тенденцию к достаточно медленному угасанию.

Указанные особенности могут свидетельствовать о наличии во временном ряде *стохастических трендов*. Для учета этих и некоторых других особенностей используется альтернативный тип нестационарных временных рядов, которые можно привести к стационарному виду не выделением тренда, а с помощью операции «*дифференцирования*», т.е. операции взятия разностей определенного порядка. Такие временные ряды называются «*стационарными относительно взятия разностей*» (*difference stationary time series*) или *интегрированными временными рядами* (*integrated time series*). Модели из данного класса нестационарных временных рядов называются *DS*-моделями. Приведем более строгое определение данного класса моделей.

> Нестационарный случайный процесс $\{X_t\}$ называется *интегрированным порядка* $d \geq 1$ (*integrated of order* d), если случайный процесс его разностей $\nabla^d X_t$ является стационарным, причем операция вычисления разностей порядка d приводит нестационарный случайный процесс X_t к стационарному виду впервые при данном значении порядка разностей.

Для интегрированного порядка d случайного процесса будем использовать обозначение $I(d)$. Через $I(0)$ будем обозначать стационарный случайный процесс, который в результате однократного «суммирования» («интегрирования») превращается в процесс типа $I(1)$.

[1] Такие особенности характерны для многих макроэкономических и финансовых переменных.

На использовании понятия «интегрированный случайный процесс» основывается определение модели *авторегрессии интегрированного скользящего среднего* (*autoregressive integrated moving average models — ARIMA model*), предложенной Дж. Боксом и Дж. Дженкинсом [2].

Говорят, что нестационарный временной ряд $\{X_t\}$ описывается *моделью авторегрессии интегрированного скользящего среднего* ARIMA(p,d,q), если временной ряд $\{X_t\}$ является *интегрированным порядка* $d \geq 1$, а временной ряд его разностей $\nabla^d X_t$ описывается стационарной и обратимой моделью ARMA(p,q).

Модель ARIMA(p,d,q) может быть представлена в виде

$$\varphi(B)\nabla^d X_t = \varphi_0 + \theta(B)W_t, \quad t = 1, 2, \ldots, T, \tag{1.6}$$

где

- $\{W_t\} \sim WN(0, \sigma^2)$ — процесс «белого шума»,
- φ_0 — свободный член,
- а разности $\nabla^d X_t$ и лаговые полиномы $\varphi(B)$, $\theta(B)$ описываются соотношениями:

$$\nabla^d X_t = (1 - B)^d X_t,$$

$$\varphi(B) \equiv 1 - \varphi_1 B - \varphi_2 B^2 - \ldots - \varphi_p B^p, \quad \theta(B) \equiv 1 - \theta_1 B - \theta_2 B^2 - \ldots - \theta_q B^q,$$

Вводя обозначение

$$\begin{aligned}\delta(B) = \varphi(B)\nabla^d = (1 - \varphi_1 B - \varphi_2 B^2 - \ldots - \varphi_p B^p)(1 - B)^d = \\ = 1 - \delta_1 B - \delta_2 B^2 - \ldots - \delta_{p+d} B^{p+d},\end{aligned} \tag{1.7}$$

из (1.6) получаем более удобное для вычисления прогнозов представление модели ARIMA(p,d,q):

$$\begin{aligned}X_t = \delta_1 X_{t-1} + \delta_2 X_{t-2} + \ldots + \delta_{p+d} X_{t-p-d} + \varphi_0 + \\ + W_t - \theta_1 W_{t-1} - \theta_2 W_{t-2} - \ldots - \theta_q W_{t-q},\end{aligned} \tag{1.8}$$

Из (1.7) следует, что для модели ARIMA(p,d,q) должны быть заданы начальные значения $X_{1-(p+d)},\ldots,X_0$ и $W_{1-q},\ldots,W_0$.

Для временного ряда разностей $x_t \equiv \nabla^d X_t$ порядка d справедливо представление в виде модели ARMA(p,q):

$$x_t = \varphi_1 x_{t-1} + \varphi_2 x_{t-2} + \ldots + \varphi_p x_{t-p} + \varphi_0 + W_t - \\ -\theta_1 W_{t-1} - \theta_2 W_{t-2} - \ldots - \theta_q W_{t-q}, \tag{1.9}$$

условия стационарности и обратимости для которой описаны в п. 3.3.

Примеры

Пример 1.6. Пусть временной ряд $\{X_t\}$ описывается моделью ARIMA(1,1,1), тогда на основании (1.7), (1.8) имеет место соотношение

$$(1-\varphi_1 B)(1-B)X_t = \varphi_0 + W_t - \theta_1 W_{t-1}, \tag{1.10}$$

откуда следует представление

$$X_t = \varphi_0 + (1+\varphi_1)X_{t-1} - \varphi_1 X_{t-2} + W_t - \theta_1 W_{t-1}. \tag{1.11}$$

Для временного ряда первых разностей $x_t \equiv \nabla X_t$ из (1.11) следует представление типа (1.9) в виде модели ARMA(1,1):

$$x_t = \varphi_0 + \varphi_1 x_{t-1} + W_t - \theta_1 W_{t-1}.$$

Пример 1.7. Если временной ряд $\{X_t\}$ описывается моделью ARIMA(0,2,1), тогда из (1.7), (1.8) (либо из (1.10), (1.11) при $\varphi_1 = 1$) получаем:

$$(1-B)(1-B)X_t = \varphi_0 + W_t - \theta_1 W_{t-1},$$
$$X_t = \varphi_0 + 2X_{t-1} - X_{t-2} + W_t - \theta_1 W_{t-1},$$

откуда для временного ряда вторых разностей $x_t \equiv \nabla^2 X_t = X_t - 2X_{t-1} + X_{t-2}$ получается представление в виде модели MA(1): $x_t = \varphi_0 + W_t - \theta_1 W_{t-1}$.

4.1.4. Процессы «единичного корня»

Модель «случайное блуждание»

Рассмотрим вначале простейшую, но часто встречаемую в практических исследованиях модель «процесса единичного корня». Для временного ряда $\{X_t\}$ запишем представление в виде модели AR(1) со свободным членом и «белым шумом» $\{W_t\}$ в качестве ошибок наблюдения:

$$X_t = \varphi_0 + \varphi_1 X_{t-1} + W_t, \quad t = 1, 2, \ldots, T. \tag{1.12}$$

Временной ряд $\{X_t\}$ является стационарным при $0 < \varphi_1 < 1$[2] и нестационарным при $\varphi_1 \geq 1$ (см. п. 3.3). Рассмотрим вначале случай, когда $\varphi_1 = 1$.

Если в модели (1.12) положить $\varphi_1 = 1$, то модель принимает вид

$$X_t = \varphi_0 + X_{t-1} + W_t, \quad t = 1, 2, \ldots, T, \tag{1.13}$$

и известна как *модель случайного блуждания с дискретным временем*. Выражение (1.13) описывает модель случайного блуждания

- «*со сносом*», если $\varphi_0 \neq 0$, и
- «*без сноса*», если $\varphi_0 = 0$.

[2] При моделировании многих реальных (например, экономических или финансовых) временных рядов уместно полагать, что $\varphi_1 > 0$

Если X_0 — заданное начальное значение, то решение разностного стохастического уравнения (1.13) имеет вид

$$X_t = X_0 + \varphi_0 t + \sum_{i=1}^{t-1} W_i + W_t, \tag{1.14}$$

откуда следует, что

$$\mu_{x,t} = \mathbf{E}\{X_t\} = X_0 + \varphi_0 t, \quad \sigma^2_{x,t} = \mathbf{D}\{X_t\} = \sigma^2_W t, \quad \varphi_{k,t} = (t-k)\sigma^2_W,$$

$$\rho_{k,t} = \frac{t-k}{\sqrt{t(t-k)}} = \sqrt{\frac{t-k}{t}} = \sqrt{1-\frac{k}{t}} \quad (t \geq k > 0). \tag{1.15}$$

Таким образом, процесс случайного блуждания со сносом является нестационарным как по среднему значению, так и по дисперсии. Кроме того, если t значительно больше k, то значения АКФ $\rho_{k,t}$ близки к единице ($\rho_{k,t} \to 1$ при $k/t \to 0$, $T \to \infty$), вследствие чего временной ряд представляется сильно сглаженным.

В представлении (1.14) можно выделить четыре компонента, определяющих значение процесса случайного блуждания со сносом в некоторый момент времени t:

1) *начальное значение* временного ряда X_0;

2) *детерминированный* линейный тренд $\varphi_0 t$;

3) *стохастический тренд* $\sum_{i=1}^{t-1} W_i$, зависящий от случайных величин (инноваций) $\{W_i\}$, соответствующих «прошлым» моментам времени $i \leq t-1$;

4) *случайная ошибка наблюдения* W_t в рассматриваемый момент времени.

Прогнозные значения временного ряда для моментов времени $t = 1, 2, \ldots, T$ по доступной в предшествующий момент времени информации определяются на основании (1.14) как условные математические ожидания [**?**]:

$$\mathbf{E}\{X_t | X_0, X_1, \ldots, X_{t-1}\} = X_0 + \varphi_0 t + \sum_{i=1}^{t-1} W_i,$$

и, следовательно, формируется под влиянием как детерминированного, так и стохастического тренда.

Очевидно, наличие стохастического тренда

- является причиной нарушения обычного для TS-моделей «*свойства регулярного возврата к долгосрочному среднему значению*», определяемому величиной $X_0 + \varphi_0 t$,
- а также обуславливает *высокую степень его инерционности* (все воздействия на процесс в виде инноваций $\{W_i\}$ сохраняются в стохастическом тренде).

Процесс случайного блуждания $\{X_t\}$ вида (1.13) является примером интегрированного процесса I(1), поскольку временной ряд его первых разностей является стационарным процессом белого шума со средним значением φ_0:

$$\nabla X_t = \varphi_0 + W_t, \quad t = 1, 2, \ldots, T.$$

Характеристическое уравнение для модели (1.13) принимает вид $\lambda - \varphi_1 = 0$. Поэтому условие $\varphi_1 = 1$ означает, что единственный характеристический корень этого уравнения равен 1. По этой причине процессы типа (1.13) часто называют *процессами единичного корня* (*unit root process*).

В общем случае модель интегрированного временного ряда $I(d)$ ($d \geq 1$) содержит d *единичных корней*. Такой ряд может быть приведен к стационарному виду $\nabla^d X_t$ путем d-кратного взятия разностей. Таким образом, модель ARIMA(p,d,q) описывает процессы единичного корня, содержащие d ($d \leq p$) единичных корней.

На рис. 4.3, 4.4 приведены графики реализаций процесса I(1), порождаемых моделями случайного блуждания соответственно без сноса ($\varphi_0 = 0$, $X_0 = 70$, $\{W_t\}$ – н.о.р.с.в. $\sim \mathbb{N}_1(0, 6)$, $T = 100$) и со сносом ($\varphi_0 = 3$, $X_0 = 0$, $\{W_t\}$ — н.о.р.с.в. $\sim \mathbb{N}_1(0, 9)$, $T = 100$).

Приведем некоторые другие важные примеры процессов единичного корня.

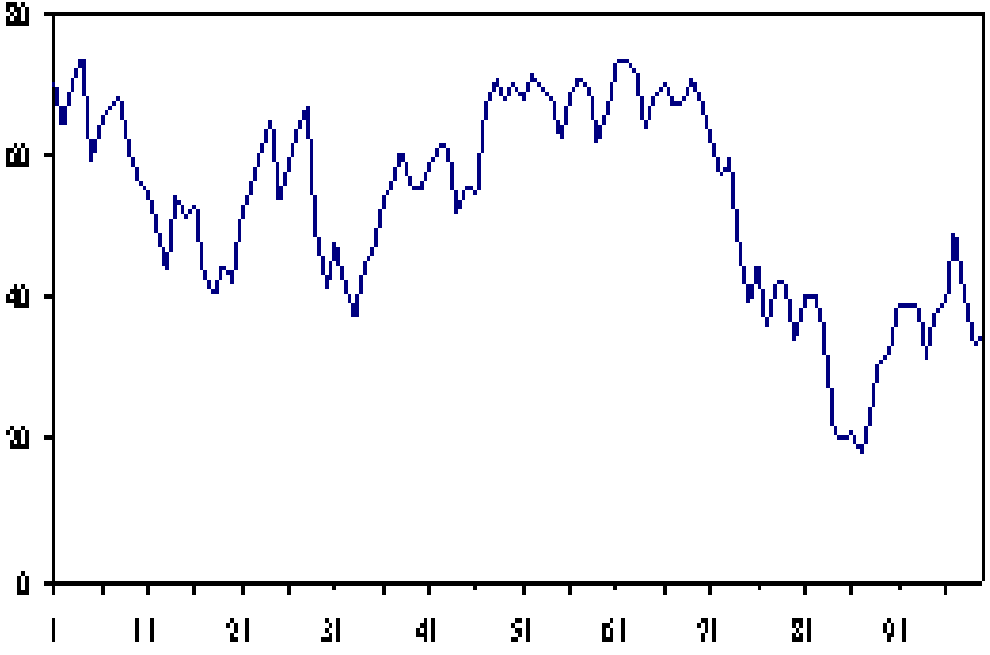


Рисунок 4.3. Процесс случайного блуждания без сноса ($\varphi_0 = 0$)

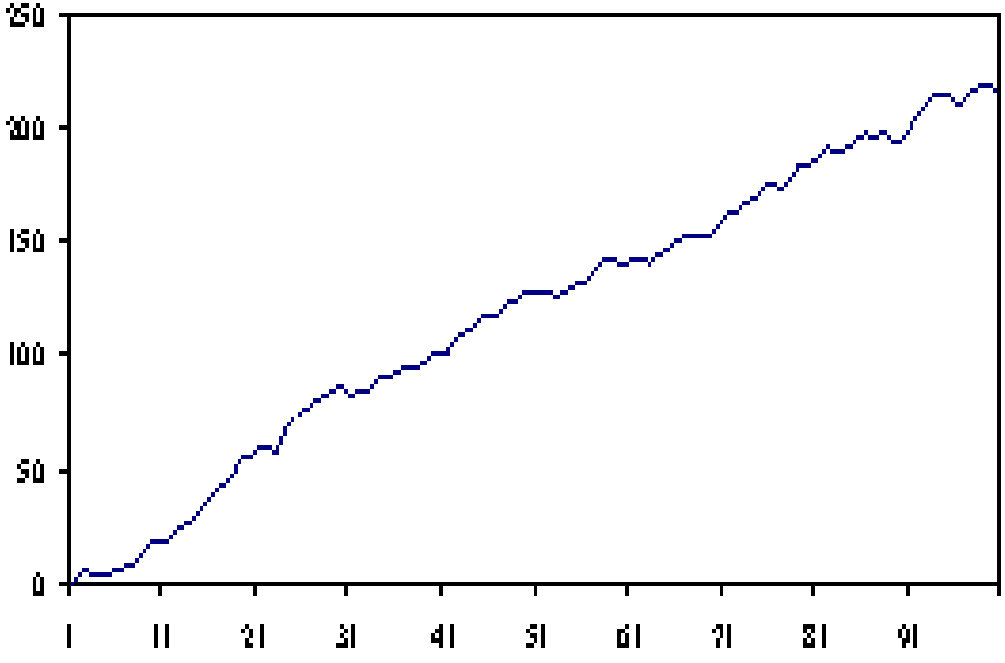


Рисунок 4.4. Процесс случайного блуждания со сносом ($\varphi_0 = 3$)

Модель «случайное блуждание плюс белый шум»

Данная модель принимает вид

$$X_t = \mu_t + W_t, \tag{1.16}$$

$$\mu_t = \mu_{t-1} + \zeta_t, \quad t = 1, 2, \ldots, T, \tag{1.17}$$

где $\{W_t\}$, $\{\zeta_t\}$ — взаимно некоррелированные процессы белого шума, для которых

$$\mathbf{E}\{\zeta_t\} = \mathbf{E}\{W_t\} = 0,$$

$$\mathbf{D}\{\zeta_t\} = \sigma_\zeta^2 < \infty,\ \mathbf{D}\{W_{t-l}\} = \sigma_W^2 < \infty \text{ и } \mathbf{E}\{\zeta_t W_{t-l}\} = 0\,\forall t, l \geq 1.$$

Формула (1.17) описывает процесс случайного блуждания без сноса μ_t с начальным значением μ_0.

Решение стохастического разностного уравнения (1.17) имеет вид

$$\mu_t = \mu_0 + \sum_{i=1}^{t-1} \zeta_i + \zeta_t, \quad t = 1, 2, \ldots, T.$$

Подставляя данное представление для μ_t в (1.16) и учитывая, что $X_0 = \mu_0 + W_0$, а $\mu_0 = X_0 - W_0$, получаем

$$X_t = \mu_0 + \sum_{i=1}^{t-1} \zeta_i + \zeta_t + W_t = X_0 - W_0 + \sum_{i=1}^{t-1} \zeta_i + \zeta_t + W_t. \tag{1.18}$$

Укажем на некоторые свойства полученного представления модели.

Свойство 1. В структуре модели, согласно (1.18), можно выделить три компонента:

1) долгосрочное среднее значение в виде «безусловного» математического ожидания $\mathbf{E}X_t = X_0 - W_0$;

2) стохастический тренд $\sum_{i=1}^{t-1} \zeta_i$, порождаемый процессом случайного блуждания $\{\mu_t\}$ и зависящий в момент времени t от случайных инноваций $\{\zeta_i\}$, $i \leq t-1$;

3) случайный «шумовой» компонент $\zeta_t + W_t$.

Свойство 2. Процесс X_t является нестационарным по дисперсии, так как $\mathbf{D}X_t = \sigma_\zeta^2 t + \sigma_W^2 \to \infty$ при $t \to \infty$.

Свойство 3. Значения АКФ для модели «случайное блуждание плюс белый шум» $\rho_{t,k}^{RW+WN}$ и модели случайного блуждания $\rho_{t,k}^{RW}$ (вида (1.13)) удовлетворяют неравенству

$$\rho_{t,k}^{RW+WN} = \frac{(t-k)\sigma_\zeta^2}{\sqrt{(t\sigma_\zeta^2+\sigma_W^2)((t-k)\sigma_\zeta^2+\sigma_W^2)}} < \rho_{t,k}^{RW}, \tag{1.19}$$

т.е. график временного ряда, описываемого моделью «случайное блуждание плюс белый шум», является более «размытым», чем график, соответствующий процессу случайного блуждания.

Свойство 4. Основанная на данной модели прогнозная функция допускает представление

$$X_{t+l} = X_t - W_t + \sum_{i=1}^{l} \zeta_i + W_{t+l}, \quad l \geq 1.$$

В соответствии с данной моделью ожидаемое в момент времени t значение временного ряда X_{t+l} в будущий период времени l определяется условным математическим ожиданием:

$$\mathbf{E}_t\{X_{t+l}\} = X_t - W_t,$$

и равно текущему значению X_t, уменьшенному на величину случайного воздействия W_t в текущий момент времени.

Модель с комбинированным трендом и случайной стационарной составляющей

Вместо модели случайного блуждания без сноса (1.17) наряду с соотношением (1.16) рассмотрим модель случайного блуждания со сносом вида

$$\mu_t = \varphi_0 + \mu_{t-1} + \zeta_t, \quad t = 1, 2, \ldots, T,$$

где φ_0 — константа, соответствующая параметру сноса. Полагая, что μ_0 — заданное начальное значение, получаем решение данного стохастического разностного уравнения в виде

$$\mu_t = \mu_0 + \varphi_0 t + \sum_{i=1}^{t-1} \zeta_i + \zeta_t,$$

Используя в (1.16) в качестве случайных воздействий произвольный стационарный случайный процесс $\varphi(B)W_t$, получаем модель вида

$$\mu_t = \mu_0 + \varphi_0 t + \sum_{i=1}^{t-1} \zeta_i + \zeta_t + \varphi(B)W.$$

Данная модель содержит тренд, который представляет собой комбинацию детерминированного тренда $\varphi_0 t$ и стохастического тренда $\sum_{i=1}^{t-1} \zeta_i$, а также случайную составляющую в виде стационарного процесса $\zeta_t + \varphi(B)W$.

4.1.5. «Взрывные» случайные процессы

Рассмотрим временной ряд $\{X_t\}$, описываемый моделью типа авторегрессии первого порядка AR(1):

$$X_t = \varphi_1 X_{t-1} + W_t, \quad t = 1, 2, \ldots, \tag{1.20}$$

где X_0 — заданное начальное значение, $\{W_t\}$ — процесс белого шума. Предположим, что для модели (1.20) не выполняется условие стационарности, причем $\varphi_1 > 1$. Разностное уравнение (1.20) имеет следующее решение:

$$X_t = X_0 \varphi_1^t + \sum_{i=1}^{t-1} \varphi_1^i W_{t-i} + W_t. \tag{1.21}$$

В представлении (1.21) может выделить следующие компоненты:

1) *детерминированный тренд* в виде показательной (экспоненциальной) функции времени $X_0\varphi_1^t$, который при заданном начальном значении X_0можно рассматривать как математическое ожидание временного ряда: $\mathbf{E}\{X_t\} = X_0\varphi_1^t$.

2) *стохастический тренд* $\sum\limits_{i=1}^{t-1} \varphi_1^i W_{t-i}$, зависящий от случайных величин (инноваций) $\{W_i\}$, соответствующих «прошлым» моментам времени $1 \le i \le t-1$;

4) *случайная ошибка наблюдения* W_t в рассматриваемый момент времени.

Согласно (1.21), дисперсия временного ряда $\{X_t\}$ с учетом формулы для суммы геометрической прогрессии определяется выражением

$$\mathbf{D}\{X_t\} = \frac{\varphi_1^{2t} - 1}{\varphi_1^2 - 1}\sigma_W^2,$$

из которого следует, что при $t \to \infty$ дисперсия X_t неограниченно возрастает: $\mathbf{D}\{X_t\} \to \infty$.

Условное математическое ожидание для X_t вычисляется по формуле

$$\mathbf{E}\{X_t|X_0, X_1, \ldots, X_{t-1}\} = X_0\varphi_1^t + \sum_{i=1}^{t-1}\varphi_1^i W_{t-i}, \quad t = 1, 2, \ldots, T,$$

и, следовательно, формируется под влиянием как детерминированного, так и стохастического тренда. Таким образом, временной ряд $\{X_t\}$ вида (1.20) при $\varphi_1 > 1$ является нестационарным как по среднему значению, так и по дисперсии, причем рост X_t имеет экспоненциальный или *«взрывной»* (*explosive*) характер роста. На этом основании такие процессы часто называют «*взрывными случайными процессами*».

Данный класс моделей нестационарных временных рядов можно рассматривать как альтернативу описанным выше моделям временных рядов, «стационарных относительно детерминированного тренда» и «стационарных относительно взятия разностей». Взрывной характер роста характерен для курсов некоторых финансовых активов, например, курсов акций, которые принято называть *спекулятивными*, или *рациональными пузырями* (*speculative or rational bubbles*). Рост курсов таких активов объясняется не экономическими, а спекулятивными факторами. Для их описания не применимы традиционные подходы. В частности, имеющий место в данном случае стохастический тренд не может быть полностью исключен ни с помощью взятия разностей, ни с помощью выделения детерминированного тренда, и поэтому для построения модели результирующего временного ряда остатков нельзя использовать подход Бокса–Дженкинса. Более подробное обсуждение данной проблемы можно найти в [**?**, **?**].

4.2. Методы построения моделей нестационарных временных рядов

4.2.1. Построение моделей временных рядов с детерминированными трендами
4.2.2. Методы построения и тестирования модели ARIMA
4.2.3. Особенности построения сезонной модели ARIMA
4.2.4. Методы тестирования процессов единичного корня

4.2.1. Построение моделей временных рядов с детерминированными трендами

Процесс построения модели временного ряда с детерминированным трендом включает:

1) выделение тренда, т.е. выбор вида функции тренда, и оценивание параметров для заданной функции тренда;

2) проверка адекватности и сравнительный анализ построенных моделей для альтернативных вариантов функций тренда.

Если рассматриваемая функция тренда линейна по параметрам либо допускает линеаризацию за счет специальных функциональных преобразований, то для оценивания параметров используется линейный метод наименьших квадратов. В частности, для оценивания параметров полиномиального (линейного по параметрам) тренда в регрессионной модели (1.5) применяется линейный метод наименьших квадратов. Если функция не может быть преобразована к линейному по параметрам виду, то может использоваться нелинейный метод наименьших квадратов.

Анализ адекватности модели основан на использовании стандартного набора тестовых статистик с целью решения следующих задач (см. п. 4.1.3):

1) анализ значимости коэффициентов регрессии и адекватности модели в целом (t-статистика для коэффициентов регрессии, F-статистика для проверки незначимости одновременно всех коэффициентов регрессии, коэффициент детерминации модели R^2, сумма квадратов остатков RSS);

2) проверка предположения о том, что остатки являются гауссовым белым шумом, т.е. являются некоррелированными (используются статистики ВАКФ, ВЧАКФ, Q-статистика Льюнга–Бокса и др.) и имеют нормальный закон распределения (критерии хи-квадрат Пирсона, Жака-Бера и др.).

Признаками статистически адекватной модели являются статистически значимые оценки параметров выбранной функции тренда и остатки, описываемые процессом гауссового белого шума.

Выбор наилучшей модели из альтернативных вариантов статистически адекватных моделей, различающихся функцией тренда, осуществляется на основе сравнительного анализа характеристик точности аппроксимации наблюдаемых значений временного ряда [**?**] типа MAPE, RMSE, коэффициента Тейла, а также с помощью информационных статистик Акаике (AIC), Шварца (SC) и др.

4.2.2. Методы построения и тестирования модели ARIMA

Для построения моделей ARIMA(p,d,q) традиционно используется подход Бокса-Дженкинса [2]. Процесс построения модели ARIMA включает два этапа:

1) определения порядка d интегрированности нестационарного временного ряда $\{X_t\}$ и вычисления временного ряда разностей $x_t = \nabla^d X_t$;

2) подбор наилучшей модели для стационарного временного ряда разностей $\{x_t\}$ в классе моделей ARMA.

На первом этапе для проверки стационарности временного ряда и определения порядка d интегрированности для нестационарного временного ряда применяется анализ ВАКФ, ВЧАКФ как для самого временного ряда, так и для его разностей, а также используются «*тесты единичного корня*» (см. п. 4.2.4). На втором этапе для построения и выбора модели ARMA используется методология, описанная в главе 3.4.

4.2.3. Особенности построения сезонной модели ARIMA

Многие экономические временные ряды подвержены сезонным колебаниям, т.е. содержат регулярную сезонную составляющую, отражающую сезонные изменения (сезонный рост или сезонное снижение) анализируемого показателя. Период сезонности s обычно считается известным. Так, $s = 4$ для квартальных и $s = 12$ для месячных временных рядов. В случае сезонных временных рядов методология Бокса-Дженкинса в целом остается без изменений. Однако включает дополнительный этап, целью которого является обнаружение и исключение сезонных эффектов, т.е. приведение временного ряда к виду, пригодному для построения модели в виде ARMA.

Для исключения *«сильной» сезонности* (*strong seasonality*), т. е. ярко выраженной и достаточно регулярной сезонности *с периодом сезонности* s используется процедура взятия *сезонной разности* (*seasonal difference*) *порядка* s, которая для временного ряда X_t определяется следующим образом:

$$(1 - B^s)X_t = X_t - X_{t-s}.$$

Реальные экономические ряды часто представляют собой комбинации сезонных и трендовых компонент. Приведение подобных временных рядов к стационарному виду требует исключения тренда. Как известно, у нестационарных интегрированных временных рядов $I(d)$ тренд исключается с помощью взятия простых разностей порядка d.

Результат взятия простой разности порядка d ($d \geq 1$) по отношению к временному ряду $\{X_t\}$ после исключения сезонности с периодом s определяется соотношением

$$y_t \equiv (1 - B)^d(1 - B^s)X_t = (1 - B)(X_t - X_{t-s}) = X_t - X_{t-1} - X_{t-s} - X_{t-s-1}.$$

Если порядки сезонной и простой разности определены правильно, то есть основание предполагать, что результирующий временной ряд $\{y_t\}$ описывается стационарной и обратимой моделью ARMA(p, q), построение которой осуществляется в соответствии с методологией Бокса–Дженкинса (см. п. **??**). Исходный временной ряд $\{X_t\}$ при этом удовлетворяет сезонной модели ARIMA(p,d,q).

Учет сезонности путем взятия сезонных разностей не всегда позволяет исключить все сезонные эффекты. Для их описания в ARMA-модели результирующего временного ряда $\{y_t\}$ могут использоваться два типа *моделей сезонностей*:

– *аддитивная сезонность*;

– *мультипликативная сезонность*.

Тип модели устанавливается при помощи анализа ВАКФ и ВЧАКФ. На практике обычно рассматриваются альтернативные варианты моделей. Выбор лучшего из них осуществляется в соответствии с принципом экономности модели на основе методологии Бокса-Дженкинса.

В рамках модели *аддитивной сезонности* в ARMA-модель для $\{y_t\}$ добавляются AR- и MA-компоненты с соответствующими лагами. Модель *мультипликативной сезонности* принимает во внимание взаимодействие ARMA-модели и сезонных эффектов.

Приведем примеры ARMA-модели с сезонными эффектами. Пусть $\{y_t\}$ — стационарный временной ряд, для описания которого без учета сезонных эффектов может быть принята модель ARMA(1,1), определяемая соотношением

$$(1 - \varphi_1 B)y_t = (1 - \theta_1 B)W_t.$$

В тоже время анализ ВАКФ и ВЧАКФ говорит о наличии сезонных эффектов для некоторых лагов. Опишем некоторые возможные варианты моделей временного ряда для различных типов моделей сезонностей.

Модели аддитивной сезонности

Если единственным статистически значимым значением ВАКФ или ВЧАКФ является значение, соответствующее лагу s, то целесообразно добавить в модель соответственно сезонный MA-компонент или сезонный AR-компонент порядка s. Результатом таких модификаций будут следующие модели.

AS.1. *Добавление отдельного AR-компонента*:

$$(1 - \varphi_1 B)y_t = \varphi_s y_{t-s} + (1 - \theta_1 B)W_t;$$

AS.2. *Добавление отдельного MA-компонента*:

$$(1 - \varphi_1 B)y_t = (1 - \theta_1 B)W_t - \theta_r W_{t-r}$$ [3]

[3] Знак «-» перед коэффициентом скользящего среднего θ_r используется для сохранения принятого в учебном пособии представления для моделей скользящего среднего.

Модели мультипликативной сезонности

Наличие сезонных эффектов, проявляющееся в статистически значимых значениях ВАКФ или ВЧАКФ, кратных s, может быть учтено при использовании сезонного скользящего среднего (модель MS.1) или сезонной авторегрессии (модель MS.2) порядка s:

MS.1. $(1-\varphi_1 B)y_t = (1-\theta_1 B)(1-\theta_s B^s)W_t$;

MS.2. $(1-\varphi_1 B)(1-\varphi_s B^s)y_t = (1-\theta_1 B)W_t$.

Использование *мультипликативной сезонности* предпочтительнее в смысле принципа экономности модели. Так, например, сравним две альтернативные модели: модель мультипликативной сезонности MS.1 и модель AS.2', которая учитывает тот же сезонный эффект путем добавления MA-компонент для лагов s и $s+1$:

MS.1. $y_t = \varphi_1 y_{t-1} + W_t - \theta_1 W_{t-1} - \theta_r W_{t-s} + \theta_1\theta_r W_{t-s-1}$;

AS.2'. $y_t = \varphi_1 y_{t-1} + W_t - \theta_1 W_{t-1} - \theta_r W_{t-s} - \theta_{r+1} W_{t-s-1}$.

В случае модели MS.1 достаточно оценить три коэффициента (φ_1, θ_1, θ_s), поскольку $\theta_{r+1} = \theta_1\theta_r$, в то время как построение модели AS.2' требует оценивания четырех коэффициентов (φ_1, θ_1, θ_s и θ_{s+1}).

4.2.4. Методы тестирования процессов единичного корня

Для временного ряда $\{X_t\}$ запишем представление в виде модели AR(1) со свободным членом и «белым шумом» $\{W_t\}$ в качестве ошибок наблюдения:

$$X_t = \varphi_0 + \varphi_1 X_{t-1} + W_t, \quad t = 1, 2, \ldots, T. \tag{2.1}$$

Как следует из приведенных выше примеров, величина параметра φ_1 в модели (2.1) критическим образом влияет на тип модели временного ряда. На практике актуальной является проблема выбора между двумя следующими случаями:

1) $\varphi_1 = 1$, т. е. временной ряд $\{X_t\}$ является нестационарным и описывается моделью единичного корня (случайного блуждания);

2) $\varphi_1 < 1$, т.е. временной ряд $\{X_t\}$ является стационарным и описывается моделью AR(1).

Используемый в рамках методологии Бокса-Дженкинса анализ ВАКФ позволяет сделать предварительные выводы относительно нестационарности временного ряда. Однако такой анализ не позволяет установить тип нестационарности, поскольку медленное убывание ВАКФ при увеличении значения лага может быть обусловлено различными причинами:

– наличием единичных корней;

– наличием детерминированного временного тренда;

– близкими к 1 значениями характеристических корней.

Таким образом, подобный анализ не позволяет установить тип нестационарности, т.е. отличить стохастический тренд от детерминированного. Кроме того, в последнем случае временной ряд является стационарным, и поэтому при анализе ВАКФ возникает опасность принять стационарный *процесс «почти единичного корня»* (*near unit root process*) за нестационарный процесс.

По этой причине для установления типа нестационарности и определения порядка интегрированности для интегрированных нестационарных временных рядов используются специальные статистические тесты, получившие название «*тесты единичного корня*» (*unit root tests*).

Приведем краткое описание одного наиболее важного семейства тестов единичного корня — тестов Дики-Фуллера [4].

Тест Дики-Фуллера *(Dickey-Fuller test — DF-тест)*

В терминах теории статистической проверки гипотез задача выбора из описанных выше альтернатив может рассматриваться как задача проверки гипотезы H_0 о том, что тестируемый временной ряд является нестационарным при конкурирующем предположении H_1 о стационарности временного ряда. Таким образом, проверяются гипотезы:

$$H_0 : \varphi_1 = 1, \quad H_1 : \varphi_1 < 1, \tag{2.2}$$

по реализации временного ряда $\{X_t\}$ $(t = 1, 2, \ldots, T)$ на некотором заданном уровне значимости ε.

Формальная проверка гипотезы H_0 вида (2.2) о значении параметра φ_1 модели (2.1) на основе стандартной t-статистики (см. гл. **??**) некорректна, поскольку временные ряды в обеих частях соотношения (2.1) нестационарны, и распределение тестовой статистики отличается от стандартного t-распределения Стьюдента. Соответственно в качестве пороговых значений для тестовой статистики в рассматриваемом случае не могут использоваться квантили данного распределения. По этой причине Д. Дики и У. Фуллер предложили перейти от модели (2.1) к модели со стационарным временным рядом в левой части. Пороговые значения для тестовой статистики в данном случае отличаются от квантилей стандартного t-распределения, однако могут быть получены с помощью статистического моделирования. Тестируемая модель при этом допускает следующие расширения:

- дополнительное включение константы (свободного члена) θ_0;
- дополнительное включение константы θ_0 и линейного детерминированного тренда $\theta_2 t$.

[4] Dickey D. A., Fuller W. A. Distribution of the Estimators for Autoregressive Time Series with a Unit Root // Journal of the American Statistical Association, №74, 1979. P. 427-431.

Таким образом, возможны три варианта модели, тестируемой с помощью DF-теста ($t = 1, 2, \ldots, T$):

$$\nabla X_t = \theta_1 X_{t-1} + W_t, \tag{2.3}$$

$$\nabla X_t = \theta_0 + \theta_1 X_{t-1} + W_t, \tag{2.4}$$

$$\nabla X_t = \theta_0 + \theta_1 X_{t-1} + \theta_2 t + W_t, \tag{2.5}$$

где $\theta_1 = \varphi_1 - 1$, $\{W_t\}$ — процесс белого шума.

Очевидно, задача проверки гипотез (2.2) эквивалентна тестированию гипотез вида

$$H_0 : \theta_1 = 0, \qquad H_1 : \theta_1 < 0. \tag{2.6}$$

Процедура тестирования включает два этапа: оценивание параметров моделей (2.3)-(2.5) с помощью МНК и проверку гипотезы о значимости коэффициента регрессии θ_1 с помощью критерия, основанного на «t-статистике» Дики-Фуллера:

$$\text{гипотеза } H_0 \begin{cases} \text{не отклоняется}, & \text{если } t_T > \Delta, \\ \text{отклоняется}, & \text{если } t_T \le \Delta, \end{cases}$$

где $\Delta = \Delta(\varepsilon) < 0$ — пороговое значение, зависящее от уровня значимости ε, $t_T = \hat{\theta}_1 / \nu$ – статистика Дики-Фуллера, в которой ν — стандартная ошибка оценки $\hat{\theta}_1$.

Различным вариантам моделей (2.3)-(2.5) соответствуют различные пороговые значения $\Delta(\varepsilon)$ статистики Дики-Фуллера, которые вычислены и представлены в виде таблиц для трех различных уровней значимости $\varepsilon \in \{0.01, 0.05, 0.1\}$ и различных значений длины ряда (см. табл. П.6).

Расширенный тест Дики-Фуллера

Описанный тест предполагает некоррелированность случайных ошибок наблюдения $\{W_t\}$ в тестируемой модели. Если остатки построенной тестовой модели являются автокоррелированными, то следует применять его модификацию в виде расширенного DF-теста (*Augmented Dickey–Fuller test — ADF-тест*). В данном случае вместо моделей (2.3)-(2.5) используются модели с лагами по ∇X_t вида:

$$\nabla X_t = \theta_1 X_{t-1} + \sum_{i=2}^{p} \beta_i \nabla X_{t-i-1} + W_t, \tag{2.7}$$

$$\nabla X_t = \theta_0 + \theta_1 X_{t-1} + \sum_{i=2}^{p} \beta_i \nabla X_{t-i-1} + W_t, \tag{2.8}$$

$$\nabla X_t = \theta_0 + \theta_1 X_{t-1} + \theta_2 t + \sum_{i=2}^{p} \beta_i \nabla X_{t-i-1} + W_t, \tag{2.9}$$

В случае ADF-теста критические значения тестовых статистик остаются такими же, как и в случае DF-теста для соответствующих моделей. Однако возникает дополнительная задача выбора значения порядка авторегрессии p. Обычно она решается путем последовательного тестирования моделей, соответствующих различным значениям данного параметра ($p = p^* - 1,\ p^* - 2, \ldots$), начиная с некоторого достаточно большого значения p^*. Руководствуясь «*принципом экономности*» (*principle of parsimony*), среди адекватных моделей предпочтение отдается модели с меньшим значением p. При этом используются критерии Акаике и Шварца и др. (см. п. 4.1.3). Согласно этим критериям, «лучшей модели» соответствуют меньшие значения соответствующих статистик.

Если гипотеза H_0 вида (2.6) для тестируемого временного ряда X_t не отклоняется, то принимается решение о том, что $X_t \sim I(d)$ ($d \geq 1$), и возникает проблема определения порядка интегрированности d.

В связи с этим процедура тестирования на основе тестов Дики–Фуллера реализуется в несколько этапов.

Этап 1. Тестируется исходный временной ряд X_t. Тестовая модель формулируется для первых разностей ∇X_t в виде (2.3)-(2.5) или (2.7)-(2.9). Если гипотеза H_0 отклоняется, то ряд X_t считается стационарным ($X_t \sim I(0)$) либо относится к классу TS-моделей, если в тестовую модель включается тренд ($\theta_2 \neq 0$). Если гипотеза H_0 не отклоняется, то полагается, что $X_t \sim I(d)$ ($d \geq 1$), и для определения значения d процедура тестирования повторяется на втором этапе.

Этап 2. Тестируется временной ряд ∇X_t. В качестве тестовой модели используется модель для вторых разностей $\nabla^2 X_t$. Используется аналогичное правило принятия решения. Если гипотеза H_0 отклоняется, то ряд ∇X_t. считается стационарным, т.е. $X_t \sim I(1)$. Если гипотеза H_0 не отклоняется, то считается, что рассматриваемый временной ряд является интегрированным более высокого порядка, т.е. $X_t \sim I(d)$ ($d \geq 2$), и процедура тестирования повторяется для разностей более высокого порядка (в большинстве практических случаев $d \leq 2$).

Если временной ряд не интегрированный либо тест отвергает верную гипотезу о порядке интегрированности, то может наблюдаться эффект *излишнего взятия разностей* (*over differencing*), который проявляется в скачкообразном увеличении значения статистики Дики-Фуллера (вместо ожидаемого ее уменьшения). При этом коэффициент детерминации для построенной модели регрессии принимает значение, близкое к единице.

Следует помнить, что тесты Дики-Фуллера нельзя применять к временным рядам, содержащим структурные и сезонные изменения, а также в случае гетероскедастичных ошибок наблюдения. В указанных и других случаях, связанных с нарушением модельных предположений, следует использовать специально разработанные тесты:

- тест Филлипса–Перрона (*Philips-Perron test*) при нарушении гипотезы о некоррелированности и гомоскедастичности ошибок наблюдения в тестируемой модели;
- тест Перрона в случае, когда альтернативой интегрированному временному ряду выступает TS-модель со структурными изменениями;
- сезонный тест Дики–Гасжа–Фуллера (*Dickey-Hasza-Fuller seasonal integration test* — *DHF test*) при наличии сезонных эффектов в квартальных и месячных данных;
- сезонный *HEGY*-тест для квартальных *данных (HEGY seasonal integration test for quarterly data*).

Перечисленные тесты имеют малую мощность при тестировании стационарных процессов «почти единичного корня», для которых $\varphi_1 \approx 1$ (но $\varphi_1 < 1$): часто выносятся ошибочные решения о наличии единичных корней, т.е. об интегрированности временных рядов. Подобная ситуация имеет место при тестировании TS-моделей со структурными изменениями, а также в случае коротких временных рядов.

Литература

[1] *Андерсон Т.* Статистический анализ временных рядов. М. : Мир, 1976.

[2] *Бокс Дж., Дженкинс Г.* Анализ временных рядов. Прогноз и управление. Вып. 1, 2. М.: Мир, 1974.

[3] *Кендалл М.* Временные ряды – М.: Финансы и статистика, 1981.

[4] *Лукашин Ю.П.* Адаптивные методы краткосрочного прогнозирования — М.:Статистика, 1979.

[5] *Малла С.* Вэйвлеты в обработке сигналов. М.: Мир, 2005.

[6] *Отнес Р., Эноксон Л.* Прикладной анализ временных рядов. Основные методы. – М.: Мир, 1982.

[7] *Brockwell P.J., Davis P.A.* Time Series: Theory and Methods. – Springer Verlag, 1991.

[8] *Brown T.B., Forsythe A.B.* The small simple behavior of some statistics which test the equality of the several means //Technometrics – 1974, vol. 16, pp. 129–132.

[9] Forcasting and time series analysis. – N.Y.: W&S, 1988.

[10] *Greene W.* Econometric Analysis. N. Y.: Macmillan Rublishing Company, 1993.

[11] *Grandell, J.* Time series analysis / J. Grandell
`https://www.math.kth.se/matstat/gru/sf2943/ts.pdf`